# CCGtown: Alat Anotasi Combinatory Categorial Grammar (CCG) Semi-otomatis Berbasis Web

Tugas Akhir
diajukan untuk memenuhi salah satu syarat
memperoleh gelar sarjana
dari Program Studi Informatika
Fakultas Informatika
Universitas Telkom

1301160479 Wisnu Adi Nurcahyo



Program Studi Sarjana Informatika
Fakultas Informatika
Universitas Telkom
Bandung

2021

## LEMBAR PENGESAHAN

CCGtown: Alat Anotasi Combinatory Categorial Grammar (CCG)
Semi-otomatis Berbasis Web

 $CCGtown: A \ Web-based \ Semi-automatic \ Combinatory \ Categorial$   $Grammar \ (CCG) \ Annotation \ Tool$ 

NIM: 1301160479

### Wisnu Adi Nurcahyo

Tugas akhir ini telah diterima dan disahkan untuk memenuhi sebagian syarat memperoleh gelar pada Program Studi Sarjana Informatika

Fakultas Informatika Universitas Telkom

Bandung, 20 Januari 2021 Menyetujui

Pembimbing I

Dr. Ade Romadhony, S.T., M.T.

NIP: 06840042

Ketua Program Studi Sarjana Informatika,

Niken Dwi Wahyu Cahyani, S.T., M.Kom. PhD

NIP: 00750052

# LEMBAR PERNYATAAN

Dengan ini saya, Wisnu Adi Nurcahyo, menyatakan sesungguhnya bahwa Tugas Akhir saya dengan judul "CCGtown: Alat Anotasi Combinatory Categorial Grammar (CCG) Semi-otomatis Berbasis Web" beserta dengan seluruh isinya adalah merupakan hasil karya sendiri, dan saya tidak melakukan penjiplakan yang tidak sesuai dengan etika keilmuan yang belaku dalam masyarakat keilmuan. Saya siap menanggung resiko/sanksi yang diberikan jika dikemudian hari ditemukan pelanggaran terhadap etika keilmuan dalam buku TA atau jika ada klaim dari pihak lain terhadap keaslian karya.

Bandung, 20 Januari 2021 Yang Menyatakan,

Wisnu Adi Nurcahyo

#### CCGtown: Alat Anotasi Combinatory Categorial Grammar (CCG) Semi-otomatis Berbasis Web

### Wisnu Adi Nurcahyo<sup>1</sup>, Ade Romadhony<sup>2</sup>

<sup>1,2</sup>Fakultas Informatika, Universitas Telkom, Bandung <sup>1</sup>nurcahyo@student.telkomuniversity.ac.id, <sup>2</sup>aderomadhony@telkomuniversity.ac.id

#### Abstrak

Dalam pemrosesan bahasa alami, combinatory categorial grammar (CCG) merupakan salah satu formalisme tata bahasa yang dapat digunakan untuk membangun sebuah parser yang umumnya dikenal sebagai CCG parser. CCG parser dapat digunakan untuk berbagai macam keperluan dalam pemrosesan bahasa alami. Sebagai contoh, CCG parser dapat digunakan untuk memperoleh informasi (information extraction) dari suatu kalimat yang kemudian membentuk sebuah query. Agar dapat membangun CCG parser ataupun tools lainnya, ketersediaan dataset CCG yang memuat CCG lexicon sangat diperlukan. Saat Tugas Akhir ini ditulis, dataset CCG untuk bahasa Indonesia belum tersedia. Demikian itu, CCGtown dibangun sebagai annotation tool yang dapat digunakan untuk membangun dataset CCG. CCGtown merupakan open source graphical annotation tool berbasis web yang dirancang dengan fokus mempercepat serta mempermudah proses penganotasian. Dengan fitur generate CCG derivation serta auto-assign CCG category kegiatan repetitif dalam melakukan anotasi akhirnya berkurang. Dengan antarmuka (UI/UX) yang cukup baik menjadikan CCGtown alat anotasi yang mudah digunakan (user friendly) oleh berbagai kalangan pengguna.

Kata kunci: pemrosesan bahasa alami, combinatory categorial grammar, alat anotasi

Abstract TBA.

Keywords: natural language processing, combinatory categorial grammar, annotation tool

#### 1. Pendahuluan

#### Latar Belakang

Riset pemrosesan bahasa alami untuk bahasa Indonesia saat ini masih terbilang sedikit. Bahkan, masih banyak area riset yang belum tersentuh seperti contohnya combinatory categorial grammar (CCG). Sementara itu, riset mengenai CCG untuk bahasa Inggris sudah cukup matang. Adapun untuk bahasa lainnya (seperti bahasa Vietnam) sudah mulai menggunakan CCG di dalam penelitiannya [5]. Agar dapat menerapkan CCG di dalam aplikasi yang dibangun, tools seperti CCG parser dan CCG supertagger harus tersedia terlebih dahulu. Masing-masing dari tools tersebut memerlukan dataset agar dapat memberikan hasil yang akurat.

Umumnya terdapat dua cara yang paling sering digunakan untuk mengembangkan CCG supertagger maupun CCG parser bahasa lokal yaitu (1) membangun dataset CCG supertag secara manual maupun semi-otomatis atau (2) melakukan transfer dataset dari CCGbank (atau dari sumber lainnya) ke dalam bahasa lokal dengan cara melakukan alih bahasa dan bila perlu melakukan penyesuaian untuk supertagnya [2]. Proses pembangunan dataset umumnya menggunakan bantuan annotation tool agar proses anotasinya menjadi lebih mudah. Salah satu annotation tool yang dapat digunakan adalah CCGweb [1].

Tugas akhir ini berusaha untuk membangun alat anotasi CCG baru dengan UI/UX yang lebih baik dari CCGweb. Selain itu, dengan bantuan NLTK alat anotasi ini dapat melakukan generate untuk CCG derivation-nya kemudian pengguna juga dapat mengubah derivation-nya apabila diperlukan. Tujuan dari dibangunnya alat anotasi CCG ini adalah untuk mempermudah proses anotasi yang repetitif. Selanjutnya, dataset CCG pertama untuk bahasa Indonesia diharapkan dapat dipublikasikan.

#### Topik dan Batasannya

Anotasi berdasarkan KBBI merupakan sebuah catatan yang dibuat oleh pengarang atau orang lain untuk menerangkan, mengomentari, atau mengkritik teks karya sastra atau bahan tertulis lain. Dalam konteks pemrosesan bahasa alami, anotasi merupakan sebuah catatan yang digunakan untuk merepresentasikan suatu makna tertentu. Representasi tersebut umumnya sesuatu yang dapat "dipahami" oleh komputer. Sebagai contoh, pada kalimat "Pamungkas kemarin makan rendang" kita dapat memberikan anotasi "Pamungkas [ORANG] kemarin makan rendang [MAKANAN]". Maksud dari anotasi tersebut yaitu "Pamungkas" dalam kalimat tersebut merupakan representasi dari orang sebagai subjeknya dan "rendang" merupakan representasi dari makanan sebagai objeknya. Memberikan anotasi secara manual merupakan kegiatan yang melelahkan. Demikian itu, alat anotasi dikembangkan untuk membantu meringankan proses pemberian anotasi.

Alat anotasi untuk pemrosesan bahasa alami yang tersedia sejatinya sudah cukup banyak. Jenis, kemampuan, dan biaya masing-masing alat anotasi tersebut juga beragam. Sebagai contoh, tagtog¹ merupakan alat anotasi berbasis web yang dapat digunakan secara gratis maupun berbayar. Selain tagtog, prodigy² juga merupakan alat anotasi berbasis web tetapi tidak dapat digunakan secara gratis. Selain itu, prodigy mendukung lebih banyak tipe anotasi seperti Named Entity, POS Tagging, Dependency Parsing, dan lain-lain. Kendati banyaknya alat anotasi yang sudah tersedia, dukungan anotasi untuk Combinatory Categorial Grammar (CCG) belum banyak. Salah satu alat anotasi CCG dengan antarmuka grafis yang tersedia adalah CCGweb³.

CCG. Secara UI dan UX, CCGweb masih membutuhkan banyak perbaikan. Selain itu, kemampuan yang dimiliki CCGweb juga masih sangat terbatas. Demikian itu, dalam Tugas Akhir ini kami mencoba untuk mengembangkan alat anotasi CCG berbasis web baru dengan UI dan UX yang lebih baik serta fitur yang lebih banyak. Beberapa fitur yang kami tambahkan adalah kemampuan untuk membuat lebih dari satu proyek anotasi dalam satu akun, dapat melakukan generate CCG derivation (turunan CCG) dengan bantuan NLTK selama anotasi CCG yang diberikan absah, dapat melakukan perubahan terhadap CCG derivation secara langsung, serta dapat melakukan pemberian anotasi secara otomatis terhadap token kata yang masih belum diberikan anotasinya berdasarkan anotasi-anotasi yang telah diberikan sebelumnya terhadap kata yang sama. Adapun alat anotasi CCG yang kami kembangkan diberi nama CCGtown.

Anotasi CCG sebenarnya memiliki bentuk yang rumit. Anotasi CCG memiliki bentuk sintaktik dan bentuk semantik. Bentuk (S/N) yang akan dilihat pada bagian selanjutnya merupakan bentuk sintaktik dari CCG. Adapun :  $\lambda x.\lambda y.$  suka(y,x) yang akan dilihat pada bagian selanjutnya merupakan bentuk semantik dari CCG. Bentuk sintaktik CCG sejatinya juga dapat lebih kompleks ketimbang hanya memiliki bentuk (S/N) saja. Akan tetapi, CCGtown saat ini ekspektasinya hanya dapat digunakan untuk anotasi CCG yang bentuknya sederhana. Hal tersebut dikarenakan terbatasnya sumber dataset yang dapat dijadikan sampel. Salah satu dataset yang dapat digunakan adalah CCGbank. Namun, CCGbank bukanlah dataset yang dapat dengan bebas diperoleh. Demikian itu, CCGtown menggunakan sampel yang tersedia secara terbuka saja seperti contoh kasus dari referensi yang digunakan, contoh anotasi CCG di halaman NLTK, dan sebagainya.

Fokus CCGtown pada Tugas Akhir ini adalah untuk memberikan alternatif alat anotasi CCG yang sudah tersedia yaitu CCGweb. CCGtown diharapkan dapat memberikan UI/UX yang lebih baik. Demikian itu, pengujian yang akan dilakukan adalah pengujian untuk user experience yaitu dengan menggunakan UEQ-S<sup>4</sup>. UEQ sejatinya memiliki banyak kuisioner yang perlu dijawab. Untuk mempercepat kebutuhan pengujian, kami menggunakan UEQ versi singkat yang mana hanya memiliki delapan pertanyaan. Ekspektasi banyaknya responden untuk pengujian ini setidaknya 20 responden. Akan tetapi, sulit rasanya bagi CCGtown untuk mendapatkan responden sebanyak itu karena tidak banyak orang yang mengerti apa itu Combinatory Categorial Grammar (CCG). Adapun keabsahan CCG yang sudah dianotasi kemudian diekspor tidak kami validasi karena keterbatasan sumber daya manusia dan kurangnya kebutuhan waktu. Selain itu, CCGtown saat ini ekspektasinya digunakan hanya untuk memberikan anotasi pada dataset dengan bahasa Indonesia dan bahasa Inggris saja.

#### Tujuan

CCGtown diharapkan dapat menjadi alternatif alat anotasi CCG yang memiliki UI/UX yang lebih baik. Satu-satunya alat anotasi CCG yang menjadi tolak ukur adalah CCGweb. Demikian itu, pengujian

<sup>1</sup>https://tagtog.net/

<sup>2</sup>https://prodi.gy/

https://ccgweb.phil.hhu.de/

<sup>&</sup>lt;sup>4</sup>User Experience Questionnaire Short version

yang akan dilakukan adalah dengan menggunakan User Experience Questionnaire atau biasa disingkat menjadi UEQ. Hasil dari UEQ ini kemudian dijadikan sebuah grafik yang memberikan metrik mengenai seberapa baik CCGtown berdasarkan umpan balik dari pengguna yang telah mencoba CCGtown.

#### Organisasi Tulisan

Studi Terkait menjelaskan dasar-dasar materi yang perlu diketahui sebelum beranjak ke bagian selanjutnya. Bagian tersebut membahas apa itu Categorial Grammar (CG), apa itu Combinatory Categorial Grammar (CCG), penjelasan singkat mengenai Lambda Calculus yang digunakan oleh CCG sebagai semantiknya, kemudian penjelasan singkat mengenai CCGweb. Sistem yang Dibangun menjelaskan mengenai teknologi apa saja yang digunakan, mengapa menggunakan teknologi tersebut, seperti apa desain database dan sistemnya, serta mengapa CCGtown memiliki desain UI/UX demikian. Evaluasi memberikan gambaran hasil UEQ yang telah diubah menjadi metrik dengan penjabarannya.

#### 2. Studi Terkait

#### Categorial Grammar

Categorial Grammar (CG) merupakan sebuah istilah yang mencakup beberapa formalisme terkait yang diajukan untuk sintaks dan semantik dari bahasa alami serta untuk bahasa logis dan matematis [7]. Karakteristik yang paling terlihat dari CG adalah bentuk ekstrim dari leksikalismenya di mana beban utama (atau bahkan seluruh beban) sintaksisnya ditanggung oleh leksikon. Konstituen tata bahasa dalam categorial grammar dan khususnya semua leksikal diasosiasikan dengan suatu type atau "category" (dalam category theory) yang mendefinisikan potensi mereka untuk dikombinasikan dengan konstituen lain untuk menghasilkan konstituen majemuk. Category tersebut adalah salah satu dari sejumlah kecil category dasar (seperti NP) atau functor (dalam category theory). Dalam hal ini, category dapat diartikan sebagai syntactic type dari suatu kata.

Secara formal, syntactic type didefinisikan sebagai himpunan bagian dari suatu semigroup M yang tunduk pada tiga operasi yaitu 1, 2, dan 3 dimana A, B, dan C merupakan himpunan bagian dari M [3]. Adapun  $A \cdot B$  dibaca A times B, C/B dibaca C over B, dan  $A \setminus C$  dibaca A under C. Selanjutnya, dapat dilihat bahwasannya untuk semua A, B,  $C \subseteq M$  sehingga kita dapatkan 4 dan 5. Terakhir, persamaan 6 dapat diabaikan apabila dihadapkan dengan multiplicative system yang tidak asosiatif. Sementara itu, apabila semigroup-nya merupakan sebuah monoid dengan identitas 1 maka kita dapatkan 7 dimana  $I = \{1\}$ .

$$A \cdot B = \{ x \cdot y \in M \mid x \in A \land y \in B \} \tag{1}$$

$$C/B = \{ x \in M \mid \forall_{y \in B} x \cdot y \in C \}$$
 (2)

$$A \setminus C = \{ y \in M \mid \forall_{x \in A} x \cdot y \in C \}$$
 (3)

$$A \cdot B \subseteq C$$
 jika dan hanya jika  $A \subseteq C/B$  (4)

$$A \cdot B \subseteq C$$
 jika dan hanya jika  $B \subseteq A \setminus C$  (5)

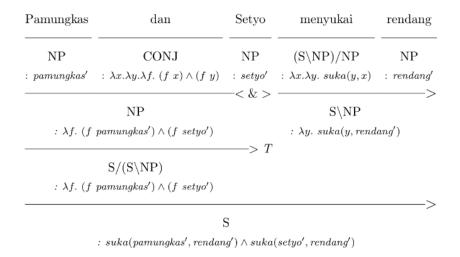
$$(A \cdot B) \cdot C = A \cdot (B \cdot C) \tag{6}$$

$$I \cdot A = A = A \cdot I \tag{7}$$

Ada beberapa notasi berbeda untuk category dalam merepresentasikan directional-nya. Notasi yang paling umum digunakan adalah "slash notation" yang dipelopori oleh Bar-Hilel, Lambek, dan kemudian dimodifikasi dalam kelompok teori yang dibedakan sebagai tata bahasa "combinatory" categorial grammar (CCG). Sebagai contoh, category (S\NP)/NP merupakan suatu functor yang memiliki dua buah notasi slash yaitu \ dan /. Masing-masing notasi slash tersebut merepresentasikan directionality yang berbeda. Notasi forward slash, /, mengindikasikan bahwa argumen dari suatu functor X/Y ada di bagian kanan atau dengan kata lain Y. Adapun backward slash, \, mengindikasikan bahwa argumen dari suatu functor X\Y ada di bagian kiri atau dengan kata lain X. Demikian itu, penggunaan notasi slash yang tepat sangat penting dikarenakan hal ini dapat mempengaruhi konstituen dari hasil "kombinasi"

Pamungkas  $\vdash$  NP : pamungkas'Setyo  $\vdash$  NP : setyo'  $dan \vdash$  CONJ :  $\lambda x.\lambda y.\lambda f.$   $(f \ x) \land (f \ y)$ menyukai  $\vdash$  (S\NP)/NP :  $\lambda x.\lambda y.$  suka(y,x)rendang  $\vdash$  NP : rendang'

Gambar 1. Kamus yang memetakan token kata ke bentuk CCG lexicon-nya.



Gambar 2. Contoh CCG derivation dengan operasi coordination, forward application, dan type rising.

category-nya.

#### Combinatory Categorial Grammar

Combinatory Categorial Grammar (CCG) merupakan salah satu formalisme tata bahasa yang gaya aturannya diturunkan dari categorial grammar dengan beberapa penambahan aturan dan istilah baru [8]. Di CCG, category dapat dipasangkan dengan semantic representation. Dalam hal ini, semantic representation yang dimaksud adalah abstraksi fungsi lambda (dalam lambda calculus, lambda function). Sebagai contoh, category (S\NP)/NP dapat dipasangkan dengan fungsi lambda  $\lambda x.fx$  sehingga dapat ditulis menjadi (S\NP)/NP:  $\lambda x.fx$ . Adapun pemetaan dari suatu token kata ke category-nya menggunakan notasi  $\vdash$ . Sebagai contoh, anggap saja kita memiliki kamus pemetaan seperti pada Gambar 1. Apabila kita memiliki kalimat "Pamungkas dan Setyo menyukai rendang", maka kita dapatkan:

Ada beberapa operasi yang dapat dilakukan dalam CCG. Operand dari operasi yang dimaksud adalah category. Berdasarkan contoh di atas, akan ada tiga operasi yang dijalankan yaitu coordination, forward application, dan type rising. Untuk mendapatkan hasil yang diinginkan, kita lakukan type rising sebelum forward application di akhir. Sehingga, kita dapatkan Gambar 2. Berdasarkan hasil evaluasi tersebut, kita dapatkan query 8 yang diperoleh dari kalimat "Pamungkas dan Setyo menyukai rendang". Demikian itu, komputer dapat melakukan komputasi berdasarkan query yang telah diperoleh. Kegiatan tersebut merupakan apa yang disebut dengan CCG parsing. Untuk dapat melakukan parsing, CCG lexicon diperlukan. Untuk mendapatkan CCG lexicon kita dapat menggunakan CCG supertagger yang akan melakukan pelabelan suatu token kata ke CCG lexicon berdasarkan pemetaannya.

$$suka(pamungkas', rendang') \land suka(setyo', rendang')$$
 (8)

#### Lambda Calculus

Lambda calculus ( $\lambda$ -calculus) merupakan sebuah formalisme yang dikembangkan oleh Alonzo Church sebagai alat yang digunakan untuk memahami konsep komputasi yang efektif [6]. Formalisme  $\lambda$ -calculus cukup populer dan bahkan dijadikan sebagai pondasi teori bagi paradigma pemrograman functional programming. Konsep utama dari  $\lambda$ -calculus adalah apa yang disebut dengan expression. Suatu expression dalam  $\lambda$ -calculus terdiri dari tiga bagian yaitu lambda notation ( $\lambda$ ), argument (seperti a, b, c, x, dan lain-lain), dan body yang dipisahkan dengan tanda titik. Sebagai contoh, fungsi lambda  $\lambda x.x$  merupakan sebuah fungsi identitas yang mengambil argumen x kemudian mengembalikan nilai x itu sendiri. Dalam hal ini, terlihat bahwa notasi  $\lambda$  merupakan sebuah penanda bagi suatu fungsi lambda. Kemudian, pengubah x setelah notasi  $\lambda$  merupakan argumen dari fungsi tersebut. Selanjutnya, tanda titik merupakan pemisah antara head dan body fungsi lambda. Terakhir, setelah tanda titik adalah body dari suatu fungsi lambda yang mana berupa expression.

Untuk mempermudah pemahaman,  $\lambda$ -calculus dapat diperlakukan seperti fungsi tanpa nama. Sebagai contoh, fungsi lambda  $(\lambda x.x + 5)$  apabila diberikan nilai 2 sehingga menjadi  $(\lambda x.x + 5)$ 2 akan dievaluasi menjadi  $\lambda(2).(2) + 5$ . Demikian itu, nilai yang dikembalikan oleh fungsi tersebut adalah 7. Sama seperti fungsi pada umumnya, konsep ini bernama substition (substitusi). Memahami  $\lambda$ -calculus dirasa perlu berhubung dalam tugas akhir ini  $\lambda$ -calculus digunakan sebagai bentuk formal di category dalam konteks CCG lexicon. Meskipun  $\lambda$ -calculus tidak sesederhana yang dijelaskan sebelumnya, setidaknya memahami  $\lambda$ -calculus seperti ini sudah cukup untuk dapat membangun supertagger yang ada di tugas akhir ini.

#### **CCGweb**

CCGweb<sup>5</sup> merupakan open source graphical annotation tool pertama untuk CCG [1]. Aplikasinya berbasis web dan dibangun dengan menggunakan bahasa pemrograman Python, PHP, dan JavaScript. Fitur yang paling menarik dari graphical annotation tool adalah What You See Is What You Get (WYSI-WYG) yang mana berupa kemampuan untuk me-render CCG derivation sesuai dengan apa yang kita lihat. Maksudnya, CCG derivation akan ditampilkan horizontal sesuai dengan panjang kalimatnya kemudian hasil derivation-nya ditampilkan vertikal seperti contoh pada Bagian 2..

Untuk dapat menggunakan CCGweb, kita perlu melakukan instalasi terlebih dahulu. Selanjutnya barulah kita dapat menambahkan kalimat-kalimat yang ingin dianotasi. Satu instalasi CCGweb hanya dapat digunakan untuk satu proyek anotasi sehingga apabila kita memiliki lebih dari satu proyek maka kita perlu melakukan instalasi CCGweb yang baru. Demikian itu, CCGtown<sup>6</sup> hadir dengan fitur *multi-project* dan tanpa perlu melakukan instalasi di komputer lokal karena aplikasinya *hosted* sehingga dapat diakses kapan pun.

#### 3. Sistem yang Dibangun

CCGtown dibangun dengan menggunakan bahasa pemrograman Python dan JavaScript. Adapun framework yang digunakan adalah Django. Versi awal CCGtown merupakan sebuah proof-of-concept dari open source graphical annotation tool berbasis web yang dilengkapi dengan fitur penganotasian semi-otomatis. Bahasa pemrograman Python digunakan karena sebagian besar library untuk CCG sudah tersedia di PyPi <sup>7</sup>. Salah satu library penting yang digunakan sebagai dasar dari fitur penganotasian semi-otomatis adalah NTLK <sup>8</sup>. Selanjutnya, Django digunakan untuk mempercepat proses pengembangan aplikasi. Adapun JavaScript digunakan untuk menjadikan CCGtown aplikasi berbasis web yang interaktif.

Alur kerja CCGtown pada umumnya adalah (1) pengguna melakukan registrasi, (2) pengguna melakukan login ke sistem, (3) pengguna membuat proyek baru, (4) pengguna menambahkan kalimat yang ingin dianotasi, (5) pengguna melakukan anotasi kemudian melakukan generate CCG derivation dan/atau melakukan modifikasi derivation-nya apabila diperlukan, dan (6) pengguna melakukan export setelah selesai melakukan anotasi. Alur kerja tersebut mempengaruhi desain sistem dari CCGtown. Salah satunya adalah desain dari database yang akan digunakan.

#### Desain Database

CCGtown menggunakan PostgreSQL sebagai  $DBMS^9$ -nya. Hal ini karena PostgreSQL memiliki kemampuan untuk menyimpan struktur data  $JSON^{10}$  sehingga memudahkan CCGtown untuk menyimpan

<sup>5</sup>https://github.com/texttheater/ccgweb

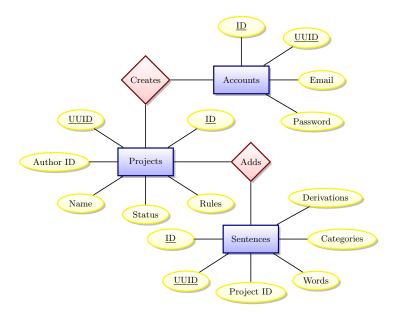
<sup>6</sup>https://github.com/wisn/ccgtown

<sup>7</sup>https://pypi.org/

<sup>8</sup>http://www.nltk.org/

<sup>&</sup>lt;sup>9</sup>Database Management System

<sup>&</sup>lt;sup>10</sup>JavaScript Object Notation



Gambar 3. Conceptual Entity Relationship Diagram (ERD) CCGtown

format JSON dari CCG derivation yang telah dimanipulasi oleh pengguna melalui fitur editable CCG derivation. PostgreSQL juga memiliki banyak fitur lain termasuk di antaranya dukungan dari non-relational database model (seperti multi-model graph) sehingga apabila di waktu yang akan datang CCGtown memerlukan perubahan signifkan terhadap desain database-nya tidak perlu mengganti DBMS yang digunakan. Fitur lain seperti function dan procedure juga akan sangat membantu pengembangan CCGtown di waktu yang akan datang.

CCGtown versi awal sejatinya hanya membutuhkan tiga tabel saja yaitu tabel accounts untuk menyimpan pengguna yang terdaftar, tabel projects untuk menyimpan proyek-proyek yang sudah dibuat, dan tabel sentences untuk menyimpan kalimat-kalimat yang akan dianotasikan. Tiga tabel tersebut sudah cukup untuk membangun proof-of-concept dari alat anotasi CCG yang akan dibangun. Adapun ERD<sup>11</sup>-nya dapat dilihat pada Gambar3.

Masing-masing tabel memiliki dua key yaitu ID dan  $UUID^{12}$ . ID merupakan primary key integer dengan auto increment yang berfungsi sebagai identifier untuk melakukan operasi update maupun delete. Adapun UUID merupakan indexed column yang berfungsi sebagai indentifier publik (dapat dilihat oleh pengguna melalui URL) yang mana digunakan untuk operasi read. ID tidak digunakan sebagai identifier publik karena pengguna dapat melakukan brute-force untuk mencari proyek ataupun kalimat berdasarkan ID yang bukan miliknya. Demikian itu alasan ditambahkannya atribut UUID. Alasan kenapa CCGtown tetap menyimpan kolom ID adalah karena ID nantinya akan digunakan untuk membuat pagination.

Pada tabel accounts, selain ID dan UUID juga memiliki atribut email dan password. Masing-masing atribut tersebut menggunakan tipe data string atau VARCHAR di PostgreSQL. Tabel accounts memiliki hubungan one-to-many terhadap tabel projects. Adapun atribut tabel projects adalah author\_id, name, status, dan rules. Atribut author\_id merupakan foreign key (indexed) yang mengarah kepada tabel accounts dan tipe data yang digunakan sama dengan atribut ID yang terdapat di tabel accounts. Atribut name menggunakan tipe data string (VARCHAR). Atribut status menggunakan tipe data integer yang berperan sebagai enum (0 = just created, 1 = in progress, 2 = finished, dan 3 = dropped). Tabel projects memiliki hubungan one-to-many terhadap tabel sentences. Adapun atribut tabel sentences adalah project\_id, words, categories, dan derivations. Atribut project\_id merupakan foreign key (indexed) yang mengarah kepada tabel projects dan tipe data yang digunakan sama dengan atribut ID yang terdapat di tabel projects. Sisanya, atribut words, categories, dan derivations menggunakan tipe data JSON.

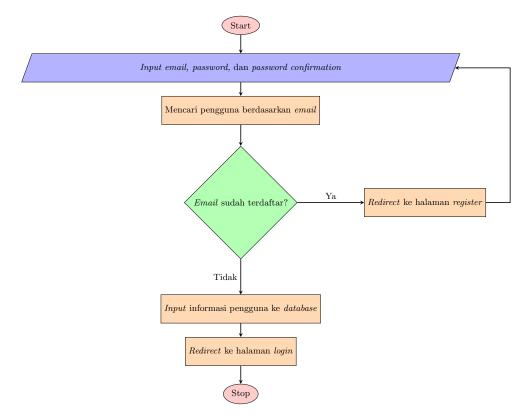
#### Desain Sistem

CCGtown sejatinya memiliki desain sistem yang cukup sederhana. Fungsionalitas yang akan didukung untuk versi awal adalah (1) register dan login, (2) manajemen proyek (CRUD<sup>13</sup>), (3) dan manajemen

 $<sup>^{11}\</sup>mathrm{Entity}$ Relationship Diagram

<sup>&</sup>lt;sup>12</sup>Universally Unique IDentifier

<sup>&</sup>lt;sup>13</sup>Create, Read, Update, Delete



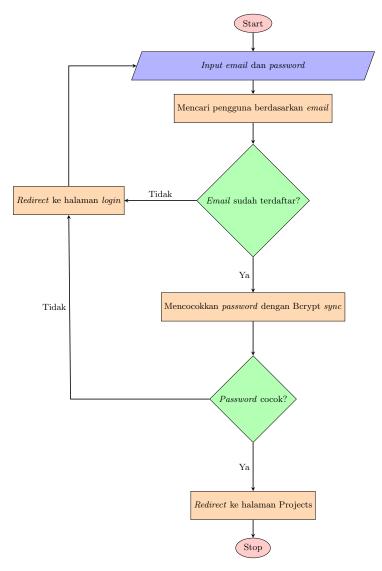
Gambar 4. Alur proses pendaftaran pengguna.

kalimat (CRUD). Pada manajemen kalimat, CCG<br/>town menggunakan JavaScript untuk membuat pembuatan maupun perubahan CCG<br/> derivation menjadi lebih interaktif. Selain tiga fungsionalitas tersebut, CCG<br/>town juga menambahkan fungsionalitas tambahan seperti <br/>auto-assign category yang dilakukan di sisi frontend. Kemudian, CCG<br/>town juga menambahkan fungsionalitas tambahan di sisi <br/>backend yaitu CCG derivation generator dengan memanfaatkan library NLTK dan kemampuan untuk melakukan export<br/>CCG derivation yang disimpan di database.

Pengguna harus terdaftar terlebih dahulu sebelum dapat melaukan anotasi sehingga langkah awal yang harus dibangun adalah fungsionalitas register. Alur proses pendaftaran pengguna dapat dilihat pada Gambar 4. Berhubung fokus saat ini adalah proof-of-concept, informasi yang dibutuhkan untuk mendaftar hanyalah email dan password. Adapun password confirmation digunakan untuk memvalidasi password sehingga dapat mengurangi risiko pengguna melupakan password-nya yang baru saja di-input. Saat pengguna melakukan pendaftaran, sistem akan memeriksa apakah email yang didaftar sudah terdapat di database. Apabila sudah terdaftar, pengguna akan dialihkan ke halaman register kembali dan mendapatkan flash message dengan keterangan "email sudah terdaftar". Sebaliknya, sistem akan melakukan input data tersebut ke dalam database lalu mengalihkan pengguna ke halaman login. Ketika dialihkan ke halaman login, pengguna akan melihat flash message dengan keterangan "pengguna berhasil didaftarkan". Pada tahap ini pengguna sudah dapat melakukan login ke dalam sistem CCGtown.

Pada proses "input informasi pengguna ke database" CCGtown melakukan password hashing dengan menggunakan Bcrypt. Informasi sensitif seperti password sebaiknya tidak disimpan sebagai plain text. Demikian itu CCGtown menggunakan password hashing. Apabila hal buruk terjadi seperti misalnya data breach (kebocoran data), password pengguna tidak dapat langsung digunakan. Peretas perlu mencari cara untuk memecahkan password tersebut. Bcrypt merupakan skema password hashing berbasis Blowfish block cipher yang didesain untuk lebih resistant terhadap serangan brute-force [4]. Serangan brute-force merupakan upaya peretas untuk menebak password dengan cara membuat wordlist yang kemudian dicocokkan dengan hash yang terbentuk satu-demi-satu. Meskipun terjadi data breach, peretas perlu usaha ekstra untuk dapat menebak password dari satu pengguna. Hal ini mengurangi kerugian yang akan dialami oleh CCGtown apabila data breach benar-benar terjadi.

Selanjutnya, setelah melakukan registrasi, pengguna dapat melakukan login ke sistem CCGtown. Proses yang dilakukan pada umumnya sama dengan aplikasi web yang memiliki kemampuan register dan login. Alur proses login dapat dilihat pada Gambar 5. Setelah pengguna melakukan input email dan



Gambar 5. Alur proses *login* ke sistem CCG.

password-nya, CCGtown akan melakukan pencarian di database apakah email yang diberikan terdaftar. Apabila tidak terdaftar, pengguna akan dialihkan ke halaman login dan diberikan flash message "Email dan/atau password tidak cocok". Pesan ini diberikan agar peretas tidak dapat mencari tahu email mana saja yang sudah terdaftar. Selanjutnya, apabila akun dengan email tersebut ada, maka langkah selanjutnya adalah mencocokkan password yang diberikan oleh pengguna dan password yang telah disimpan di database. Kemudian, sistem melakukan Berypt sync. Apabila tidak berhasil, pengguna akan dialihkan ke halaman login dan diberikan flash message "Email dan/atau password tidak cocok". Sebaliknya, pengguna akan dialihkan ke halaman Projects yang berisi daftar proyek yang telah dibuat sebelumnya.

Pada halaman Projects, pengguna dapat membuat proyek atau menghapus proyek. Tidak ada fungsionalitas spesial di halaman Projects selain CRUD pada umumnya. Satu pengguna dapat membuat banyak proyek. Tidak ada larangan tertentu terhadap penamaan proyek. Namun, sangat disarankan memberikan nama proyek yang deskriptif seperti misalnya "Wide-range Indonesian Dataset". Setiap proyek memiliki status yang berbeda-beda. Proyek yang baru saja dibuat akan memiliki status just created. Hal ini untuk memudahkan annotator mencari proyek mana yang baru akan dikerjakan, proyek mana yang sedang dikerjakan, proyek mana yang sudah selesai dikerjakan, atau proyek mana yang tidak jadi dikerjakan. Proyek yang telah dibuat dapat disunting maupun dihapus. Proyek yang dihapus tidak dapat dikembalikan (undo). Adapun penyuntingan proyek terjadi di halaman Editor.

Pada halaman Editor, pengguna dapat menyunting informasi proyek seperti nama proyek, status proyek, dan *rules* yang akan digunakan untuk melakukan *generate* CCG *derivation* via NTLK. Selain itu, pengguna juga dapat menambahkan kalimat baru yang akan dianotasi. Pengguna dapat menambahkan lebih dari satu kalimat sekaligus. Kalimat-kalimat tersebut akan di-tokenize menggunakan *library* NLTK.

Ekstensi yang digunakan untuk proses tokenize ini adalah punkt. Setelah itu, barulah pengguna dapat melakukan penganotasian terhadap kalimat-kalimat yang telah ditambahkan. Terdapat dua cara untuk memberikan anotasi yaitu secara langsung di halaman Editor atau dapat juga dilakukan di Editable CCG Modal. Saat ini CCGtown belum mendukung penganotasian terhadap compound words. CCGtown saat ini juga belum mendukung penganotasian CCG dengan semantik. Versi awal CCGtown hanya mendukung penganotasian CCG secara sintaksis saja.

Setelah semua kata dalam suatu kalimat diberikan anotasi, pengguna dapat melakukan generate CCG derivation. Hal ini dapat dilakukan berkat bantuan library NLTK. Kami mengambil sebuah rules dari tabel projects dan kemudian kami mengambil semua words serta categories dari tabel sentences yang merupakan bagian dari proyek tersebut. Kolom words merupakan kumpulan kata dari kalimat yang telah di-tokenize. Adapun kolom categories merupakan anotasi CCG category-nya. Pseudocode untuk generate CCG derivation dapat dilihat pada Kode 3.1 dengan asumsi anotasi yang diberikan absah (dapat dibuat CCG derivation-nya). Kode next tersebut akan mengambil satu dari banyak kemungkinan derivation yang dapat dibuat. Contoh object yang di-return dapat dilihat pada Kode 3.2. Untuk kepentingan rendering di sisi frontend, key seperti from dan to sangat diperlukan. Key from dan key to merepresentasikan index posisi terhadap array words. Dengan bantuan kedua key tersebut, frontend dapat melakukan kalkulasi posisi masing-masing elemen yang terdapat di object derivations.

Kode 3.1: Pseudocode untuk melakukan generate CCG derivation.

```
from nltk.ccg import chart, lexicon
 3
        generateCCGDerivation(rules, words, categories, target_words):
 4
        lex = rules +
            i in range(len(words)):
 5
                                     , + categories [i] + , \ \ \ , \\
 6
            lex += words[i] +
                                , =>
        lex = lexicon.parseLexicon(lex)
        parser = chart.CCGChartParser(lex, chart.DefaultRuleSet)
10
         result = next(parser.parse(target_words))
        derivations = makeCCGDeriv(result)
11
12
        return derivations
```

Kode 3.2 didapatkan dari fungsi make CCGDeriv yang terdapat pada Kode 3.1. Fungsi make CCGDeriv sederhananya mengambil Tree yang didapatkan dari parser.parse kemudian melakukan tree traversal. Semua leaf, diambil dari paling "kiri", diletakkan di elemen pertama derivations. Selanjutnya, kita berjalan melalui parent dari leaf tersebut hingga ke root mencari bentuk CCG derivation-nya. Banyaknya baris yang dibutuhkan oleh CCG derivation dapat dilihat dari height yang dimiliki oleh Tree tersebut. Kemudian, hasil dari CCG derivation (umumnya berupa S) merupakan elemen terakhir derivations. Adapun hasil render di sisi frontend-nya dapat dilihat pada Gambar 14.

Kode 3.2: Contoh derivations object yang di-return.

```
2
                                        "word": "You" },
"word": "prefer"
"word": "that" }
"word": "cake" }
                                    0,
 3
             "to": 0,
                         " from " :
                         "from": 1,
"from": 2,
            "to":
\begin{array}{c} 4 \\ 5 \\ 6 \\ 7 \end{array}
                     1,
                          "from": 3,
                                                         "NP" },
"((S\NP)/NP)" },
"(NP/N)" },
"N" }
            9
                                          "category
                                         "category":
10
                         "from":
                                         "category
                                    2,
11
             "to": 3,
                         "from": 3,
                                         "category
12
13
14
                                         "category": "NP", "operator": ">" }
16
17
                                                          "(S\NP)", "operator": ">" }
                  ": 3. "from": 1.
                                         "category
18
19
20
21
                         "from": 0, "category": "S", "operator": "<" }
22
23
```

Selain memiliki kemampuan untuk melakukan generate CCG derivation, CCGtown juga memiliki kemampuan untuk melakukan auto-assign CCG category. Token kata yang sudah dianotasi oleh pengguna akan disimpan ke dalam suatu dictionary. Untuk setiap kata yang belum dianotasi, CCGtown akan memerikan apakah token kata tersebut sebelumnya sudah dianotasi. Apabila sudah, CCGtown akan memberikan anotasi secara otomatis. Suatu token kata mungkin memiliki lebih dari satu anotasi.

CCGtown hanya akan mengambil satu anotasi saja. Akibatnya, pengguna sebaiknya tetap melakukan peninjauan. Kendati demikian, setidaknya kegiatan anotasi yang repetitif dapat berkurang sehingga memudahkan dan mempercepat proses anotasi.

#### Pertimbangan UI/UX

Secara keseluruhan, CCGtown memiliki halaman rumah (homepage), halaman register, halaman login, halaman Projects, dan halaman Editor. Halaman register dan halaman login pada dasarnya sama. Perbedaannya hanya terdapat di jumlah field yang diminta serta copy writting yang sedikit berbeda. Desain UI<sup>14</sup> serta UX<sup>15</sup> CCGtown dibuat dengan fokus untuk mempermudah penggunaan annotation tool ini. CCGtown tidak menggunakan banyak warna. Hal ini untuk mengurangi kelelahan pada mata pengguna. CCGtown menggunakan bahasa Inggris di antarmukanya karena target pengguna CCGtown adalah pengguna baik dari Indonesia yang mengerti bahasa Inggris maupun pengguna dari manca negara.

CCGtown menggunakan UIKit<sup>16</sup> sebagai framework untuk melakukan implementasi desain web-nya. UIKit dipilih karena komponen-komponen yang dibutuhkan CCGtown sudah tersedia sehingga CCGtown hanya perlu melakukan sedikit penyesuaian seperti penambahan warna, pengaturan jarak (margin dan padding), dan sejenisnya. UIKit juga sudah menyediakan kumpulan icons yang dapat langsung digunakan. Hal ini mengakibatkan proses pengembangan desain web CCGtown dapat diselesaikan dalam waktu yang relatif cukup singkat.

Warna utama (primary color) CCGtown adalah warna ungu. Berdasarkan psikologi warna, warna ungu adalah warna fantasi dan magis. CCGtown dapat men-generate CCG derivation dan melakukan auto-assign CCG category sehingga memiliki sifat yang seakan-akan mengandung magi (sihir). Selain itu, ungu menumbuhkan kreativitas dengan membangkitkan indra kita sambil mempromosikan ketenangan yang diperlukan untuk melakukan pengamatan yang intuitif dan berwawasan. Warna ungu banyak digunakan oleh homepage seperti yang terlihat pada Gambar 6. Halaman rumah CCGtown didesain sederhana dan langsung kepada intinya. Halaman rumah CCGtown menampilkan beberapa fitur yang dapat menjadi alasan bagi pengguna untuk menggunakan CCGtown. Selain itu, halaman rumah CCGtown juga menampilkan demonstrasi singkat dengan gambar animasi proses penganotasian di CCGtown. Demonstrasi singkat diberikan untuk memberikan gambaran kepada calon pengguna tentang betapa mudahnya menggunakan CCGtown untuk menganotasi CCG.

Pada Gambar 7 dan Gambar 8, terlihat bahwasannya halaman register dan halaman login pada dasarnya sama. Pada halaman register, informasi yang dibutuhkan hanyalah email address dan password (dengan tambahan password confirmation untuk validasi). Hal ini agar pengguna dapat dengan mudah mendaftar tanpa perlu mengisi banyak field terlebih dahulu sebelum dapat menggunakan CCGtown. Selain itu, informasi lain dari pengguna saat ini belum dibutuhkan. Apabila terjadi perubahan mengenai data pengguna, pengguna dapat memperbarui datanya di kemudian hari melaui halaman lain seperti halaman profil yang mungkin saja akan ditambahkan di CCGtown versi berikutnya.

CCGtown menggunakan flash message berupa toast untuk setiap pesan feedback yang diberikan oleh sisi backend. Sebagai contoh, pada Gambar 9 di bagian pojok kanan bawah merupakan pesan feedback yang memberikan informasi bahwasannya kombinasi email dan/atau password tidak cocok sehingga pengguna tidak dapat login. Notifikasi toast tersebut dapat langsung ditutup oleh pengguna atau akan hilang dengan sendirinya dalam waktu sekitar lima detik. Penggunaan toast yang muncul dari bawah dengan warna ungu tersebut dapat mengalihkan perhatian pengguna sehingga pengguna menyadari pesan yang disampaikan oleh backend CCGtown.

Selanjutnya, dengan asumsi pengguna baru saja mendaftar kemudian melakukan login, pengguna akan dialihkan ke halaman Projects. Halaman Projects tersebut berada di dalam empty state karena pengguna belum membuat satupun proyek. Seperti yang dapat dilihat pada Gambar 10, pengguna dapat melihat instruksi apa yang harus ia lakukan yang mana dalam hal ini adalah membuat proyek baru. Sebaliknya, apabila pengguna telah membuat proyek maka tampilan yang dilihat akan seperti pada Gambar 11. Pengguna dapat membuka halaman Editor dengan cara melakukan klik di nama proyek maupun di ikon edit. Selain itu, pengguna juga dapat langsung melakukan export to JSON melakukan klik di ikon download. Apabila pengguna merasa tidak lagi memerlukan suatu proyek, maka pengguna dapat menghapusnya dengan melakukan klik di ikon trash.

Setelah membuat proyek baru, pengguna akan melihat halaman Editor dalam *empty state* seperti yang dapat dilihat pada Gambar 12. Pada bagian kanan halaman Editor, terdapat beberapa section yaitu Project Detail yang dapat digunakan untuk mengubah nama proyek dan status proyek, Automation

<sup>&</sup>lt;sup>14</sup>User Interface

 $<sup>^{15}\</sup>mathrm{User}$ Experience

<sup>16</sup>https://getuikit.com/

Rules yang akan digunakan oleh NLTK untuk melakukan generate CCG derivation, serta CCG Lexicons yang menampilkan statistik dari jenis sintaksis CCG yang telah dianotasikan dan berapa kali ia dianotasikan. Untuk dapat menambahkan kalimat baru, pengguna hanya perlu melakukan klik di tombol "Add Sentences". Setelah itu, pengguna dapat langsung melakukan penganotasian seperti yang terlihat pada Gambar 13. Apabila pengguna telah memberikan anotasi ke semua token kata yang ada di kalimat tersebut, pengguna dapat melakukan generate CCG derivation. Hasil dari generate CCG derivation tersebut dapat dilihat pada Gambar 14.

Pengguna juga dapat langsung mengubah CCG derivation suatu kalimat secara langsung. Contohnya dapat dilihat pada Gambar 15. Pengguna dapat memberikan anotasi ke token kata di modal (editable CCG derivation) tersebut. Pengguna dapat menambahkan beberapa baris kosong sekaligus yang kemudian akan diisi oleh CCG derivation dari kalimat tersebut. Warna abu-abu menunjukkan bahwa konfigurasi dari CCG derivation di baris tersebut masih kosong. Kemudian, warna ungu menunjukkan bahwa pada bagian tersebut (baik anotasi maupun operator) tidak diisi. Perbedaan ini diberikan untuk memberikan pengguna awareness mengenai mana saja bagian yang harus diisi atau dilengkapi. Adapun konfigurasi derivation-nya terlihat pada Gambar 16. Dengan kemampuan ini pengguna dapat melakukan generate kemudian apabila ada derivation yang dirasa kurang cocok maka pengguna dapat langsung melakukan perubahan dengan mudah dan interaktif.

#### 4. Evaluasi

TBA.

4.1 Hasil Pengujian

TBA.

4.2 Analisis Hasil Pengujian

TBA.

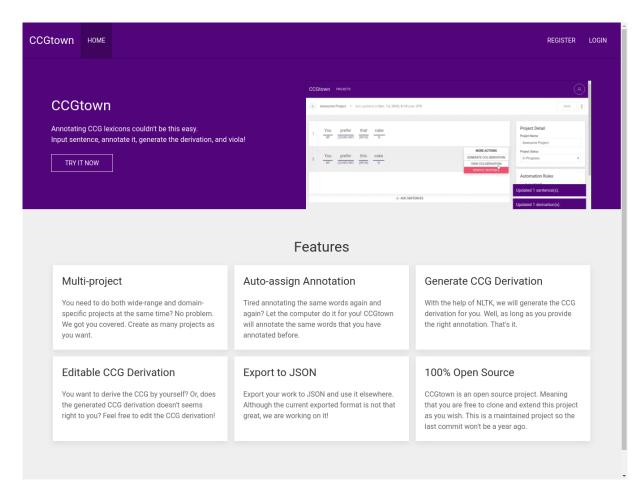
#### 5. Kesimpulan

TBA.

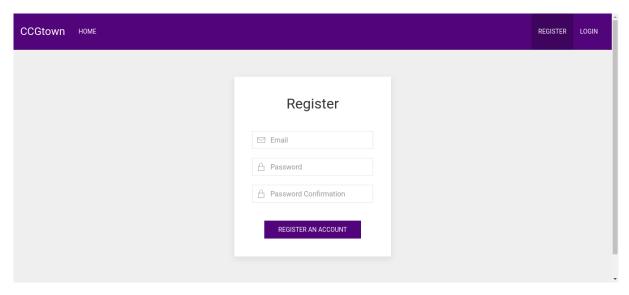
#### Daftar Pustaka

- [1] K. Evang, L. Abzianidze, and J. Bos. CCGweb: a new annotation tool and a first quadrilingual CCG treebank. In *Proceedings of the 13th Linguistic Annotation Workshop*, pages 37–42, Florence, Italy, Aug. 2019. Association for Computational Linguistics.
- [2] J. Hockenmaier and M. Steedman. CCGbank: A corpus of CCG derivations and dependency structures extracted from the Penn treebank. *Computational Linguistics*, 33(3):355–396, 2007.
- [3] J. Lambek. Categorial and Categorical Grammars, pages 297–317. Springer Netherlands, Dordrecht, 1988.
- [4] K. Malvoni, S. Designer, and J. Knezovic. Are your passwords safe: Energy-efficient bcrypt cracking with low-cost parallel hardware. 08 2014.
- [5] K. V. Nguyen and N. L.-T. Nguyen. Vietnamese transition-based dependency parsing with supertag features, 2019.
- [6] R. Rojas. A tutorial introduction to the lambda calculus. CoRR, abs/1503.09060, 2015.
- [7] M. Steedman. Categorial grammar. Technical report, 1992.
- [8] M. Steedman. A very short introduction to ccg. Technical report, 1996.

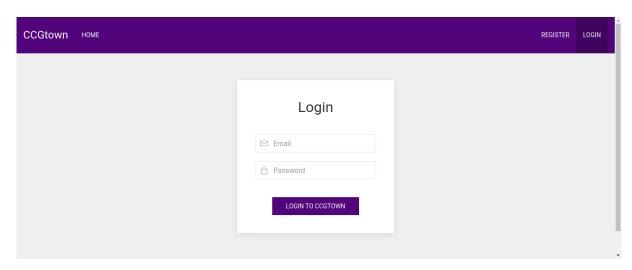
#### Lampiran



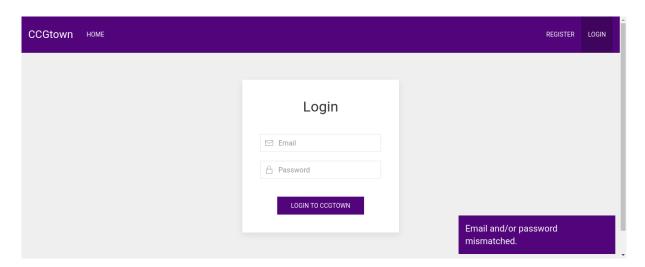
Gambar 6. Antarmuka homepage CCGtown.



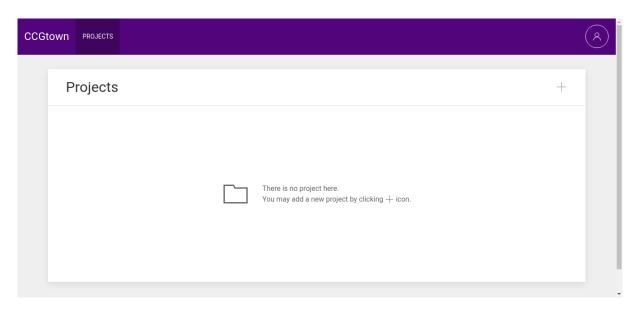
Gambar 7. Antarmuka halaman register CCGtown.



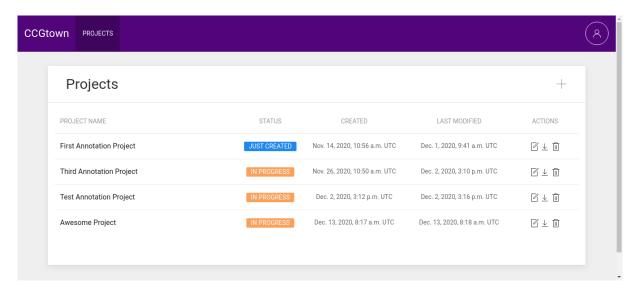
 ${\bf Gambar}$ 8. Antarmuka halaman  $\log in$  CCGtown.



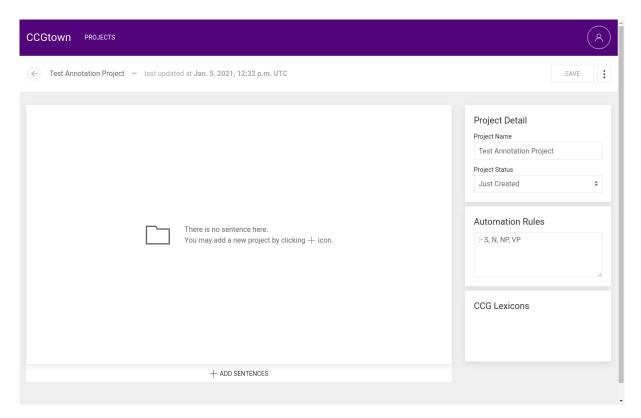
 ${\bf Gambar}$ 9. Antarmuka halaman login CCGtown dengan to ast.



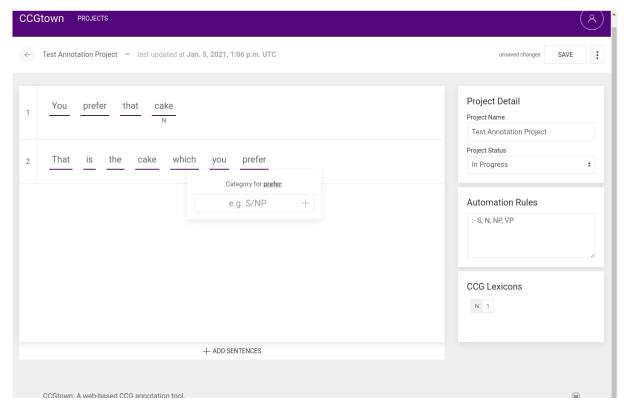
Gambar 10. Antarmuka halaman Projects saat dalam empty state.



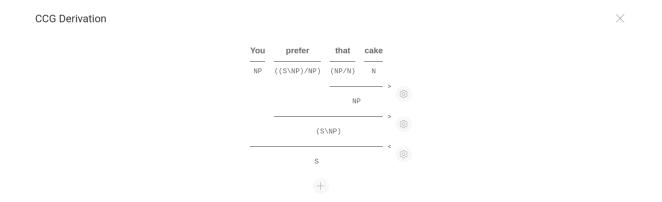
Gambar 11. Antarmuka halaman Projects CCGtown.



Gambar 12. Antarmuka halaman Editor saat dalam empty state.



Gambar 13. Antarmuka halaman Editor saat melakukan penganotasian.



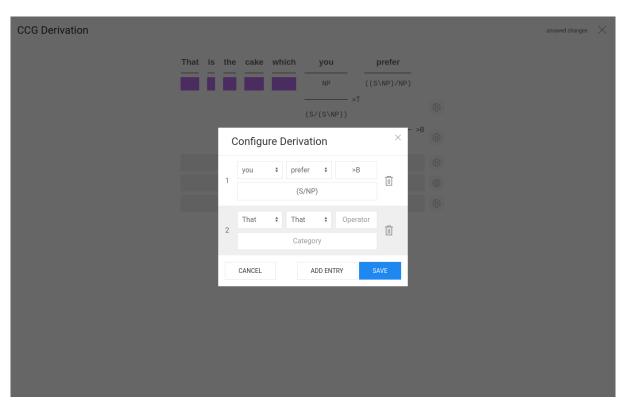
 ${\bf Gambar}$ 14. Antarmuka CCG derivation yang telah di-generate.

CCG Derivation

That is the cake which you prefer ((S\NP)/NP)

(S/(S\NP)) >8 (S/NP)

Gambar 15. Antarmuka editable CCG derivation CCGtown.



Gambar 16. Antarmuka konfigurasi dari editable CCG derivation CCGtown.