

# **CCGtown: Alat Anotasi Combinatory Categorical Grammar (CCG) Semi-otomatis Berbasis Web**

**Tugas Akhir**  
diajukan untuk memenuhi salah satu syarat  
memperoleh gelar sarjana  
dari Program Studi Informatika  
Fakultas Informatika  
Universitas Telkom

**1301160479**  
**Wisnu Adi Nurcahyo**



**Program Studi Sarjana Informatika**  
**Fakultas Informatika**  
**Universitas Telkom**  
**Bandung**

**2021**

# LEMBAR PENGESAHAN

CCGtown: Alat Anotasi Combinatory Categorical Grammar (CCG)  
Semi-otomatis Berbasis Web

*CCGtown: A Web-based Semi-automatic Combinatory Categorical  
Grammar (CCG) Annotation Tool*

NIM: 1301160479

Wisnu Adi Nurcahyo

Tugas akhir ini telah diterima dan disahkan untuk memenuhi sebagian syarat  
memperoleh gelar pada Program Studi Sarjana Informatika

Fakultas Informatika

Universitas Telkom

Bandung, 20 Januari 2021

Menyetujui

Pembimbing I

Dr. Ade Romadhony, S.T., M.T.

NIP: 06840042

Ketua Program Studi

Sarjana Informatika,

Niken Dwi Wahyu Cahyani, S.T., M.Kom. PhD

NIP: 00750052

# LEMBAR PERNYATAAN

Dengan ini saya, Wisnu Adi Nurcahyo, menyatakan sesungguhnya bahwa Tugas Akhir saya dengan judul ”**CCGtown: Alat Anotasi Combinatory Categorical Grammar (CCG) Semi-otomatis Berbasis Web**” beserta dengan seluruh isinya adalah merupakan hasil karya sendiri, dan saya tidak melakukan penjiplakan yang tidak sesuai dengan etika keilmuan yang berlaku dalam masyarakat keilmuan. Saya siap menanggung resiko/sanksi yang diberikan jika dikemudian hari ditemukan pelanggaran terhadap etika keilmuan dalam buku TA atau jika ada klaim dari pihak lain terhadap keaslian karya.

Bandung, 20 Januari 2021

Yang Menyatakan,

Wisnu Adi Nurcahyo

# CCGtown: Alat Anotasi Combinatory Categorical Grammar (CCG) Semi-otomatis Berbasis Web

Wisnu Adi Nurcahyo<sup>1</sup>, Ade Romadhony<sup>2</sup>

<sup>1,2</sup>Fakultas Informatika, Universitas Telkom, Bandung

<sup>1</sup>nurcahyo@student.telkomuniversity.ac.id, <sup>2</sup>aderomadhony@telkomuniversity.ac.id

---

## Abstrak

Dalam pemrosesan bahasa alami, combinatory categorical grammar (CCG) merupakan salah satu formalisme tata bahasa yang dapat digunakan untuk membangun sebuah *parser* yang umumnya dikenal sebagai CCG *parser*. CCG *parser* dapat digunakan untuk berbagai macam keperluan dalam pemrosesan bahasa alami. Sebagai contoh, CCG *parser* dapat digunakan untuk memperoleh informasi (*information extraction*) dari suatu kalimat yang kemudian membentuk sebuah *query*. Agar dapat membangun CCG *parser* ataupun *tools* lainnya, ketersediaan *dataset* CCG yang memuat CCG *lexicon* sangat diperlukan. Saat Tugas Akhir ini ditulis, *dataset* CCG untuk bahasa Indonesia belum tersedia. Demikian itu, CCGtown dibangun sebagai *annotation tool* yang dapat digunakan untuk membangun *dataset* CCG. CCGtown merupakan *open source graphical annotation tool* berbasis web yang dirancang dengan fokus mempercepat serta mempermudah proses pengantasian. Dengan fitur *generate CCG derivation* serta *auto-assign CCG category* kegiatan repetitif dalam melakukan anotasi akhirnya berkurang. Dengan antarmuka (UI/UX) yang cukup baik menjadikan CCGtown alat anotasi yang mudah digunakan (*user friendly*) oleh berbagai kalangan pengguna.

Kata kunci: pemrosesan bahasa alami, combinatory categorical grammar, alat anotasi

---

## Abstract

TBA.

Keywords: natural language processing, combinatory categorical grammar, annotation tool

---

## 1. Pendahuluan

### Latar Belakang

Riset pemrosesan bahasa alami untuk bahasa Indonesia saat ini masih terbilang sedikit. Bahkan, masih banyak area riset yang belum tersentuh seperti contohnya *combinatory categorical grammar* (CCG). Sementara itu, riset mengenai CCG untuk bahasa Inggris sudah cukup matang. Adapun untuk bahasa lainnya (seperti bahasa Vietnam) sudah mulai menggunakan CCG di dalam penelitiannya [5]. Agar dapat menerapkan CCG di dalam aplikasi yang dibangun, *tools* seperti CCG *parser* dan CCG *supertagger* harus tersedia terlebih dahulu. Masing-masing dari *tools* tersebut memerlukan *dataset* agar dapat memberikan hasil yang akurat.

Umumnya terdapat dua cara yang paling sering digunakan untuk mengembangkan CCG *supertagger* maupun CCG *parser* bahasa lokal yaitu (1) membangun *dataset* CCG *supertag* secara manual maupun semi-otomatis atau (2) melakukan transfer *dataset* dari CCGbank (atau dari sumber lainnya) ke dalam bahasa lokal dengan cara melakukan alih bahasa dan bila perlu melakukan penyesuaian untuk *supertag*-nya [2]. Proses pembangunan *dataset* umumnya menggunakan bantuan *annotation tool* agar proses anotasinya menjadi lebih mudah. Salah satu *annotation tool* yang dapat digunakan adalah CCGweb [1].

Tugas akhir ini berusaha untuk membangun alat anotasi CCG baru dengan UI/UX yang lebih baik dari CCGweb. Selain itu, dengan bantuan NLTK alat anotasi ini dapat melakukan *generate* untuk CCG *derivation*-nya kemudian pengguna juga dapat mengubah *derivation*-nya apabila diperlukan. Tujuan dari dibangunnya alat anotasi CCG ini adalah untuk mempermudah proses anotasi yang repetitif. Selanjutnya, *dataset* CCG pertama untuk bahasa Indonesia diharapkan dapat dipublikasikan.

### Topik dan Batasannya

Anotasi berdasarkan KBBI merupakan sebuah *catatan* yang dibuat oleh pengarang atau orang lain untuk menerangkan, mengomentari, atau mengkritik teks karya sastra atau bahan tertulis lain. Dalam konteks pemrosesan bahasa alami, anotasi merupakan sebuah *catatan* yang digunakan untuk merepresentasikan suatu makna tertentu. Representasi tersebut umumnya sesuatu yang dapat "dipahami" oleh komputer. Sebagai contoh, pada kalimat "Pamungkas kemarin makan rendang" kita dapat memberikan anotasi "Pamungkas[ORANG] kemarin makan rendang[MAKANAN]". Maksud dari anotasi tersebut yaitu "Pamungkas" dalam kalimat tersebut merupakan representasi dari orang sebagai subjeknya dan "rendang" merupakan representasi dari makanan sebagai objeknya. Memberikan anotasi secara manual merupakan kegiatan yang melelahkan. Demikian itu, alat anotasi dikembangkan untuk membantu meringankan proses pemberian anotasi.

Alat anotasi untuk pemrosesan bahasa alami yang tersedia sejatinya sudah cukup banyak. Jenis, kemampuan, dan biaya masing-masing alat anotasi tersebut juga beragam. Sebagai contoh, tagtog<sup>1</sup> merupakan alat anotasi berbasis web yang dapat digunakan secara gratis maupun berbayar. Selain tagtog, prodigy<sup>2</sup> juga merupakan alat anotasi berbasis web tetapi tidak dapat digunakan secara gratis. Selain itu, prodigy mendukung lebih banyak tipe anotasi seperti Named Entity, POS Tagging, Dependency Parsing, dan lain-lain. Kendati banyaknya alat anotasi yang sudah tersedia, dukungan anotasi untuk Combinatory Categorical Grammar (CCG) belum banyak. Salah satu alat anotasi CCG dengan antarmuka grafis yang tersedia adalah CCGweb<sup>3</sup>.

CCGweb merupakan alat anotasi berbasis web yang dikembangkan khusus untuk memberikan anotasi CCG. Secara UI dan UX, CCGweb masih membutuhkan banyak perbaikan. Selain itu, kemampuan yang dimiliki CCGweb juga masih sangat terbatas. Demikian itu, dalam Tugas Akhir ini kami mencoba untuk mengembangkan alat anotasi CCG berbasis web baru dengan UI dan UX yang lebih baik serta fitur yang lebih banyak. Beberapa fitur yang kami tambahkan adalah kemampuan untuk membuat lebih dari satu proyek anotasi dalam satu akun, dapat melakukan *generate CCG derivation* (turunan CCG) dengan bantuan NLTK selama anotasi CCG yang diberikan absah, dapat melakukan perubahan terhadap CCG *derivation* secara langsung, serta dapat melakukan pemberian anotasi secara otomatis terhadap token kata yang masih belum diberikan anotasinya berdasarkan anotasi-anotasi yang telah diberikan sebelumnya terhadap kata yang sama.

## Tujuan

TBA.

## Organisasi Tulisan

TBA.

## 2. Studi Terkait

### Categorical Grammar

Categorical Grammar (CG) merupakan sebuah istilah yang mencakup beberapa formalisme terkait yang diajukan untuk sintaks dan semantik dari bahasa alami serta untuk bahasa logis dan matematis [7]. Karakteristik yang paling terlihat dari CG adalah bentuk ekstrim dari leksikalismenya di mana beban utama (atau bahkan seluruh beban) sintaksisnya ditanggung oleh leksikon. Konstituen tata bahasa dalam *categorical grammar* dan khususnya semua leksikal diasosiasikan dengan suatu *type* atau "*category*" (dalam *category theory*) yang mendefinisikan potensi mereka untuk dikombinasikan dengan konstituen lain untuk menghasilkan konstituen majemuk. *Category* tersebut adalah salah satu dari sejumlah kecil *category* dasar (seperti NP) atau *functor* (dalam *category theory*). Dalam hal ini, *category* dapat diartikan sebagai *syntactic type* dari suatu kata.

Secara formal, *syntactic type* didefinisikan sebagai himpunan bagian dari suatu *semigroup*  $M$  yang tunduk pada tiga operasi yaitu 1, 2, dan 3 dimana  $A$ ,  $B$ , dan  $C$  merupakan himpunan bagian dari  $M$  [3]. Adapun  $A \cdot B$  dibaca  $A$  times  $B$ ,  $C/B$  dibaca  $C$  over  $B$ , dan  $A \backslash C$  dibaca  $A$  under  $C$ . Selanjutnya, dapat dilihat bahwasannya untuk semua  $A, B, C \subseteq M$  sehingga kita dapatkan 4 dan 5. Terakhir, persamaan 6 dapat diabaikan apabila dihadapkan dengan *multiplicative system* yang tidak asosiatif. Sementara itu, apabila *semigroup*-nya merupakan sebuah *monoid* dengan identitas 1 maka kita dapatkan 7 dimana  $I = \{1\}$ .

---

<sup>1</sup><https://tagtog.net/>

<sup>2</sup><https://prodi.gy/>

<sup>3</sup><https://ccgweb.phil.hhu.de/>

Pamungkas  $\vdash$  NP : *pamungkas'*  
 Setyo  $\vdash$  NP : *setyo'*  
 dan  $\vdash$  CONJ :  $\lambda x.\lambda y.\lambda f. (f\ x) \wedge (f\ y)$   
 menyukai  $\vdash$  (S\NP)/NP :  $\lambda x.\lambda y. suka(y, x)$   
 rendang  $\vdash$  NP : *rendang'*

**Gambar 1.** Kamus yang memetakan token kata ke bentuk CCG *lexicon*-nya.

$$A \cdot B = \{x \cdot y \in M \mid x \in A \wedge y \in B\} \quad (1)$$

$$C/B = \{x \in M \mid \forall y \in B\ x \cdot y \in C\} \quad (2)$$

$$A \backslash C = \{y \in M \mid \forall x \in A\ x \cdot y \in C\} \quad (3)$$

$$A \cdot B \subseteq C \quad \text{jika dan hanya jika} \quad A \subseteq C/B \quad (4)$$

$$A \cdot B \subseteq C \quad \text{jika dan hanya jika} \quad B \subseteq A \backslash C \quad (5)$$

$$(A \cdot B) \cdot C = A \cdot (B \cdot C) \quad (6)$$

$$I \cdot A = A = A \cdot I \quad (7)$$

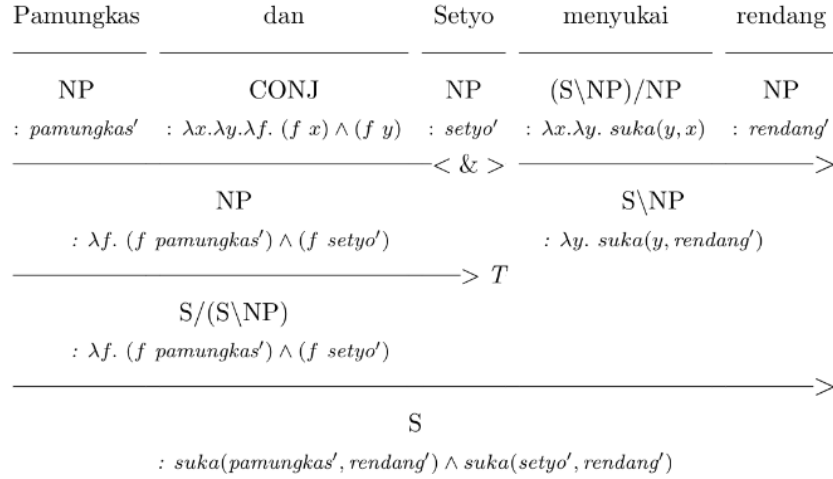
Ada beberapa notasi berbeda untuk *category* dalam merepresentasikan *directional*-nya. Notasi yang paling umum digunakan adalah “*slash notation*” yang dipelopori oleh Bar-Hilel, Lambek, dan kemudian dimodifikasi dalam kelompok teori yang dibedakan sebagai tata bahasa “*combinatory*” *categorial grammar* (CCG). Sebagai contoh, *category* (S\NP)/NP merupakan suatu *functor* yang memiliki dua buah notasi *slash* yaitu \ dan /. Masing-masing notasi *slash* tersebut merepresentasikan *directionality* yang berbeda. Notasi *forward slash*, /, mengindikasikan bahwa argumen dari suatu *functor* X/Y ada di bagian kanan atau dengan kata lain Y. Adapun *backward slash*, \, mengindikasikan bahwa argumen dari suatu *functor* X\Y ada di bagian kiri atau dengan kata lain X. Demikian itu, penggunaan notasi *slash* yang tepat sangat penting dikarenakan hal ini dapat mempengaruhi konstituen dari hasil “kombinasi” *category*-nya.

### Combinatory Categorial Grammar

Combinatory Categorial Grammar (CCG) merupakan salah satu formalisme tata bahasa yang gaya aturannya diturunkan dari *categorial grammar* dengan beberapa penambahan aturan dan istilah baru [8]. Di CCG, *category* dapat dipasangkan dengan *semantic representation*. Dalam hal ini, *semantic representation* yang dimaksud adalah abstraksi fungsi lambda (dalam *lambda calculus*, *lambda function*). Sebagai contoh, *category* (S\NP)/NP dapat dipasangkan dengan fungsi lambda  $\lambda x.f x$  sehingga dapat ditulis menjadi (S\NP)/NP :  $\lambda x.f x$ . Adapun pemetaan dari suatu token kata ke *category*-nya menggunakan notasi  $\vdash$ . Sebagai contoh, anggap saja kita memiliki kamus pemetaan seperti pada Gambar 1. Apabila kita memiliki kalimat “Pamungkas dan Setyo menyukai rendang”, maka kita dapatkan:

Pamungkas	dan	Setyo	menyukai	rendang
NP	CONJ	NP	(S\NP)/NP	NP
: <i>pamungkas'</i>	: $\lambda x.\lambda y.\lambda f. (f\ x) \wedge (f\ y)$	: <i>setyo'</i>	: $\lambda x.\lambda y. suka(y, x)$	: <i>rendang'</i>

Ada beberapa operasi yang dapat dilakukan dalam CCG. *Operand* dari operasi yang dimaksud adalah *category*. Berdasarkan contoh di atas, akan ada tiga operasi yang dijalankan yaitu *coordination*, *forward application*, dan *type rising*. Untuk mendapatkan hasil yang diinginkan, kita lakukan *type rising* sebelum *forward application* di akhir. Sehingga, kita dapatkan Gambar 2. Berdasarkan hasil evaluasi tersebut, kita dapatkan *query* 8 yang diperoleh dari kalimat “Pamungkas dan Setyo menyukai rendang”. Demikian itu, komputer dapat melakukan komputasi berdasarkan *query* yang telah diperoleh. Kegiatan tersebut merupakan apa yang disebut dengan CCG *parsing*. Untuk dapat melakukan parsing, CCG



**Gambar 2.** Contoh CCG *derivation* dengan operasi *coordination*, *forward application*, dan *type rising*.

*lexicon* diperlukan. Untuk mendapatkan CCG *lexicon* kita dapat menggunakan CCG *supertagger* yang akan melakukan pelabelan suatu token kata ke CCG *lexicon* berdasarkan pemetaannya.

$$suka(pamungkas', rendang') \wedge suka(setyo', rendang') \quad (8)$$

## Lambda Calculus

*Lambda calculus* ( $\lambda$ -*calculus*) merupakan sebuah formalisme yang dikembangkan oleh Alonzo Church sebagai alat yang digunakan untuk memahami konsep komputasi yang efektif [6]. Formalisme  $\lambda$ -*calculus* cukup populer dan bahkan dijadikan sebagai pondasi teori bagi paradigma pemrograman *functional programming*. Konsep utama dari  $\lambda$ -*calculus* adalah apa yang disebut dengan *expression*. Suatu *expression* dalam  $\lambda$ -*calculus* terdiri dari tiga bagian yaitu *lambda notation* ( $\lambda$ ), *argument* (seperti  $a$ ,  $b$ ,  $c$ ,  $x$ , dan lain-lain), dan *body* yang dipisahkan dengan tanda titik. Sebagai contoh, fungsi lambda  $\lambda x.x$  merupakan sebuah fungsi identitas yang mengambil argumen  $x$  kemudian mengembalikan nilai  $x$  itu sendiri. Dalam hal ini, terlihat bahwa notasi  $\lambda$  merupakan sebuah penanda bagi suatu fungsi lambda. Kemudian, pengubah  $x$  setelah notasi  $\lambda$  merupakan argumen dari fungsi tersebut. Selanjutnya, tanda titik merupakan pemisah antara *head* dan *body* fungsi lambda. Terakhir, setelah tanda titik adalah *body* dari suatu fungsi lambda yang mana berupa *expression*.

Untuk mempermudah pemahaman,  $\lambda$ -*calculus* dapat diperlakukan seperti fungsi tanpa nama. Sebagai contoh, fungsi lambda  $(\lambda x.x + 5)$  apabila diberikan nilai 2 sehingga menjadi  $(\lambda x.x + 5)2$  akan dievaluasi menjadi  $\lambda(2).(2) + 5$ . Demikian itu, nilai yang dikembalikan oleh fungsi tersebut adalah 7. Sama seperti fungsi pada umumnya, konsep ini bernama *substitution* (substitusi). Memahami  $\lambda$ -*calculus* dirasa perlu berhubung dalam tugas akhir ini  $\lambda$ -*calculus* digunakan sebagai bentuk formal di *category* dalam konteks CCG *lexicon*. Meskipun  $\lambda$ -*calculus* tidak sederhana yang dijelaskan sebelumnya, setidaknya memahami  $\lambda$ -*calculus* seperti ini sudah cukup untuk dapat membangun *supertagger* yang ada di tugas akhir ini.

## CCGweb

CCGweb<sup>4</sup> merupakan *open source graphical annotation tool* pertama untuk CCG [1]. Aplikasinya berbasis web dan dibangun dengan menggunakan bahasa pemrograman Python, PHP, dan JavaScript. Fitur yang paling menarik dari *graphical annotation tool* adalah What You See Is What You Get (WYSIWYG) yang mana berupa kemampuan untuk *me-render* CCG *derivation* sesuai dengan apa yang kita lihat. Maksudnya, CCG *derivation* akan ditampilkan horizontal sesuai dengan panjang kalimatnya kemudian hasil *derivation*-nya ditampilkan vertikal seperti contoh pada Bagian 2..

Untuk dapat menggunakan CCGweb, kita perlu melakukan instalasi terlebih dahulu. Selanjutnya barulah kita dapat menambahkan kalimat-kalimat yang ingin dianotasi. Satu instalasi CCGweb hanya dapat digunakan untuk satu proyek anotasi sehingga apabila kita memiliki lebih dari satu proyek maka

<sup>4</sup><https://github.com/texttheater/ccgweb>

kita perlu melakukan instalasi CCGweb yang baru. Demikian itu, CCGtown<sup>5</sup> hadir dengan fitur *multi-project* dan tanpa perlu melakukan instalasi di komputer lokal karena aplikasinya *hosted* sehingga dapat diakses kapan pun.

### 3. Sistem yang Dibangun

CCGtown dibangun dengan menggunakan bahasa pemrograman Python dan JavaScript. Adapun *framework* yang digunakan adalah Django. Versi awal CCGtown merupakan sebuah *proof-of-concept* dari *open source graphical annotation tool* berbasis web yang dilengkapi dengan fitur pengantasian semi-otomatis. Bahasa pemrograman Python digunakan karena sebagian besar *library* untuk CCG sudah tersedia di PyPi<sup>6</sup>. Salah satu *library* penting yang digunakan sebagai dasar dari fitur pengantasian semi-otomatis adalah NTLK<sup>7</sup>. Selanjutnya, Django digunakan untuk mempercepat proses pengembangan aplikasi. Adapun JavaScript digunakan untuk menjadikan CCGtown aplikasi berbasis web yang interaktif.

Alur kerja CCGtown pada umumnya adalah (1) pengguna melakukan registrasi, (2) pengguna melakukan *login* ke sistem, (3) pengguna membuat proyek baru, (4) pengguna menambahkan kalimat yang ingin dianotasi, (5) pengguna melakukan anotasi kemudian melakukan *generate CCG derivation* dan/atau melakukan modifikasi *derivation*-nya apabila diperlukan, dan (6) pengguna melakukan *export* setelah selesai melakukan anotasi. Alur kerja tersebut mempengaruhi desain sistem dari CCGtown. Salah satunya adalah desain dari *database* yang akan digunakan.

#### Desain Database

CCGtown menggunakan PostgreSQL sebagai DBMS<sup>8</sup>-nya. Hal ini karena PostgreSQL memiliki kemampuan untuk menyimpan struktur data JSON<sup>9</sup> sehingga memudahkan CCGtown untuk menyimpan format JSON dari CCG *derivation* yang telah dimanipulasi oleh pengguna melalui fitur *editable CCG derivation*. PostgreSQL juga memiliki banyak fitur lain termasuk di antaranya dukungan dari *non-relational database model* (seperti *multi-model graph*) sehingga apabila di waktu yang akan datang CCGtown memerlukan perubahan signifikan terhadap desain *database*-nya tidak perlu mengganti DBMS yang digunakan. Fitur lain seperti *function* dan *procedure* juga akan sangat membantu pengembangan CCGtown di waktu yang akan datang.

CCGtown versi awal sejatinya hanya membutuhkan tiga tabel saja yaitu tabel *accounts* untuk menyimpan pengguna yang terdaftar, tabel *projects* untuk menyimpan proyek-proyek yang sudah dibuat, dan tabel *sentences* untuk menyimpan kalimat-kalimat yang akan dianotasikan. Tiga tabel tersebut sudah cukup untuk membangun *proof-of-concept* dari alat anotasi CCG yang akan dibangun. Adapun ERD<sup>10</sup>-nya dapat dilihat pada Gambar 3.

Masing-masing tabel memiliki dua *key* yaitu *ID* dan *UUID*<sup>11</sup>. *ID* merupakan *primary key integer* dengan *auto increment* yang berfungsi sebagai *identifier* untuk melakukan operasi *update* maupun *delete*. Adapun *UUID* merupakan *indexed column* yang berfungsi sebagai *identifier* publik (dapat dilihat oleh pengguna melalui URL) yang mana digunakan untuk operasi *read*. *ID* tidak digunakan sebagai *identifier* publik karena pengguna dapat melakukan *brute-force* untuk mencari proyek ataupun kalimat berdasarkan *ID* yang bukan miliknya. Demikian itu alasan ditambahkannya atribut *UUID*. Alasan kenapa CCGtown tetap menyimpan kolom *ID* adalah karena *ID* nantinya akan digunakan untuk membuat *pagination*.

Pada tabel *accounts*, selain *ID* dan *UUID* juga memiliki atribut *email* dan *password*. Masing-masing atribut tersebut menggunakan tipe data *string* atau VARCHAR di PostgreSQL. Tabel *accounts* memiliki hubungan *one-to-many* terhadap tabel *projects*. Adapun atribut tabel *projects* adalah *author\_id*, *name*, *status*, dan *rules*. Atribut *author\_id* merupakan *foreign key (indexed)* yang mengarah kepada tabel *accounts* dan tipe data yang digunakan sama dengan atribut *ID* yang terdapat di tabel *accounts*. Atribut *name* menggunakan tipe data *string* (VARCHAR). Atribut *status* menggunakan tipe data *integer* yang berperan sebagai *enum* (0 = *just created*, 1 = *in progress*, 2 = *finished*, dan 3 = *dropped*). Tabel *projects* memiliki hubungan *one-to-many* terhadap tabel *sentences*. Adapun atribut tabel *sentences* adalah *project\_id*, *words*, *categories*, dan *derivations*. Atribut *project\_id* merupakan *foreign key (indexed)* yang mengarah kepada tabel *projects* dan tipe data yang digunakan sama dengan atribut *ID* yang terdapat di tabel *projects*. Sisanya, atribut *words*, *categories*, dan *derivations* menggunakan tipe data

---

<sup>5</sup><https://github.com/wisn/ccgtown>

<sup>6</sup><https://pypi.org/>

<sup>7</sup><http://www.nltk.org/>

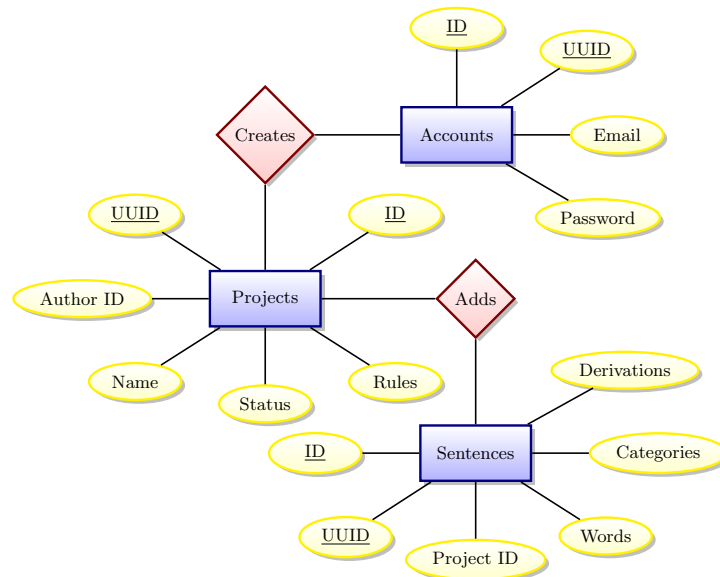
<sup>8</sup>Database Management System

<sup>9</sup>JavaScript Object Notation

<sup>10</sup>Entity Relationship Diagram

<sup>11</sup>Universally Unique Identifier





**Gambar 3.** Conceptual Entity Relationship Diagram (ERD) CCGtown

JSON.

### Desain Sistem

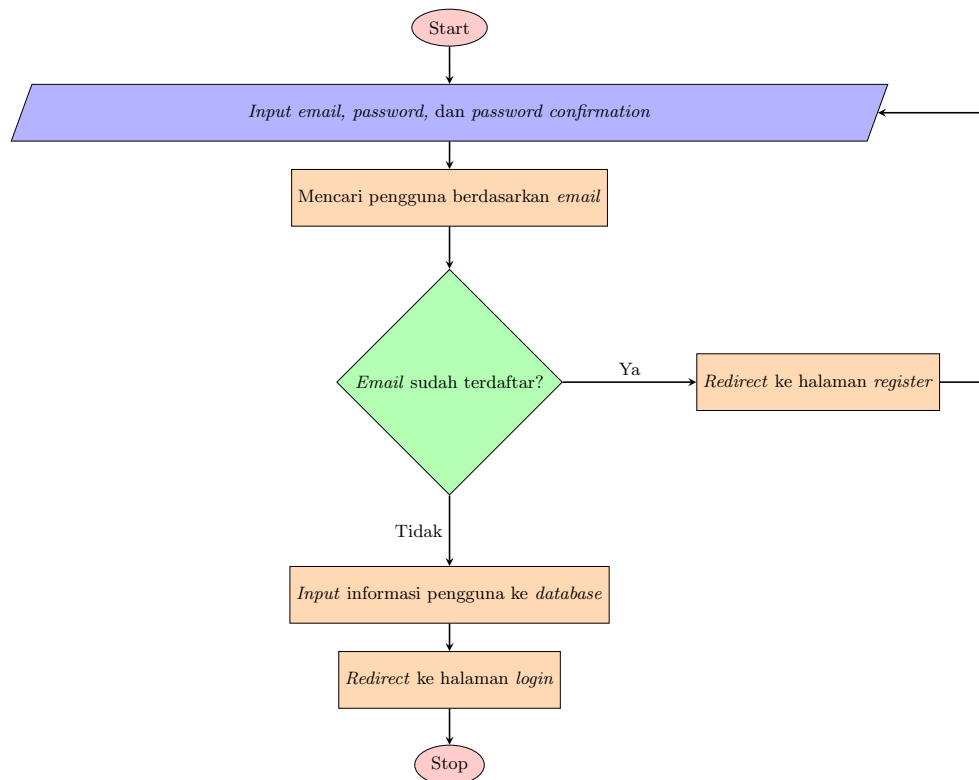
CCGtown sejatinya memiliki desain sistem yang cukup sederhana. Fungsionalitas yang akan didukung untuk versi awal adalah (1) *register* dan *login*, (2) manajemen proyek (CRUD<sup>12</sup>), (3) dan manajemen kalimat (CRUD). Pada manajemen kalimat, CCGtown menggunakan JavaScript untuk membuat pembuatan maupun perubahan CCG *derivation* menjadi lebih interaktif. Selain tiga fungsionalitas tersebut, CCGtown juga menambahkan fungsionalitas tambahan seperti *auto-assign category* yang dilakukan di sisi *frontend*. Kemudian, CCGtown juga menambahkan fungsionalitas tambahan di sisi *backend* yaitu CCG *derivation generator* dengan memanfaatkan *library* NLTK dan kemampuan untuk melakukan *export* CCG *derivation* yang disimpan di *database*.

Pengguna harus terdaftar terlebih dahulu sebelum dapat melakukan anotasi sehingga langkah awal yang harus dibangun adalah fungsionalitas *register*. Alur proses pendaftaran pengguna dapat dilihat pada Gambar 4. Berhubung fokus saat ini adalah *proof-of-concept*, informasi yang dibutuhkan untuk mendaftar hanyalah *email* dan *password*. Adapun *password confirmation* digunakan untuk memvalidasi *password* sehingga dapat mengurangi risiko pengguna melupakan *password*-nya yang baru saja di-*input*. Saat pengguna melakukan pendaftaran, sistem akan memeriksa apakah *email* yang didaftar sudah terdapat di *database*. Apabila sudah terdaftar, pengguna akan dialihkan ke halaman *register* kembali dan mendapatkan *flash message* dengan keterangan "email sudah terdaftar". Sebaliknya, sistem akan melakukan *input* data tersebut ke dalam *database* lalu mengalihkan pengguna ke halaman *login*. Ketika dialihkan ke halaman *login*, pengguna akan melihat *flash message* dengan keterangan "pengguna berhasil didaftarkan". Pada tahap ini pengguna sudah dapat melakukan *login* ke dalam sistem CCGtown.

Pada proses "input informasi pengguna ke *database*" CCGtown melakukan *password hashing* dengan menggunakan Bcrypt. Informasi sensitif seperti *password* sebaiknya tidak disimpan sebagai *plain text*. Demikian itu CCGtown menggunakan *password hashing*. Apabila hal buruk terjadi seperti misalnya *data breach* (kebocoran data), *password* pengguna tidak dapat langsung digunakan. Peretas perlu mencari cara untuk memecahkan *password* tersebut. Bcrypt merupakan skema *password hashing* berbasis Blowfish *block cipher* yang didesain untuk lebih *resistant* terhadap serangan *brute-force* [4]. Serangan *brute-force* merupakan upaya peretas untuk menebak *password* dengan cara membuat *wordlist* yang kemudian dicocokkan dengan *hash* yang terbentuk satu-demi-satu. Meskipun terjadi *data breach*, peretas perlu usaha ekstra untuk dapat menebak *password* dari satu pengguna. Hal ini mengurangi kerugian yang akan dialami oleh CCGtown apabila *data breach* benar-benar terjadi.

Selanjutnya, setelah melakukan registrasi, pengguna dapat melakukan *login* ke sistem CCGtown. Proses yang dilakukan pada umumnya sama dengan aplikasi web yang memiliki kemampuan *register* dan *login*. Alur proses *login* dapat dilihat pada Gambar 5. Setelah pengguna melakukan *input email* dan

<sup>12</sup>Create, Read, Update, Delete




**Gambar 4.** Alur proses pendaftaran pengguna.

*password*-nya, CCGtown akan melakukan pencarian di *database* apakah *email* yang diberikan terdaftar. Apabila tidak terdaftar, pengguna akan dialihkan ke halaman *login* dan diberikan *flash message* "Email dan/atau *password* tidak cocok". Pesan ini diberikan agar peretas tidak dapat mencari tahu *email* mana saja yang sudah terdaftar. Selanjutnya, apabila akun dengan *email* tersebut ada, maka langkah selanjutnya adalah mencocokkan *password* yang diberikan oleh pengguna dan *password* yang telah disimpan di *database*. Kemudian, sistem melakukan Bcrypt *sync*. Apabila tidak berhasil, pengguna akan dialihkan ke halaman *login* dan diberikan *flash message* "Email dan/atau *password* tidak cocok". Sebaliknya, pengguna akan dialihkan ke halaman Projects yang berisi daftar proyek yang telah dibuat sebelumnya.

Pada halaman Projects, pengguna dapat membuat proyek atau menghapus proyek. Tidak ada fungsionalitas spesial di halaman Projects selain CRUD pada umumnya. Satu pengguna dapat membuat banyak proyek. Tidak ada larangan tertentu terhadap penamaan proyek. Namun, sangat disarankan memberikan nama proyek yang deskriptif seperti misalnya "Wide-range Indonesian Dataset". Setiap proyek memiliki status yang berbeda-beda. Proyek yang baru saja dibuat akan memiliki status *just created*. Hal ini untuk memudahkan *annotator* mencari proyek mana yang baru akan dikerjakan, proyek mana yang sedang dikerjakan, proyek mana yang sudah selesai dikerjakan, atau proyek mana yang tidak jadi dikerjakan. Proyek yang telah dibuat dapat disunting maupun dihapus. Proyek yang dihapus tidak dapat dikembalikan (*undo*). Adapun penyuntingan proyek terjadi di halaman Editor.

Pada halaman Editor, pengguna dapat menyunting informasi proyek seperti nama proyek, status proyek, dan *rules* yang akan digunakan untuk melakukan *generate CCG derivation* via NLTK. Selain itu, pengguna juga dapat menambahkan kalimat baru yang akan dianotasi. Pengguna dapat menambahkan lebih dari satu kalimat sekaligus. Kalimat-kalimat tersebut akan di-*tokenize* menggunakan *library* NLTK. Ekstensi yang digunakan untuk proses *tokenize* ini adalah punkt. Setelah itu, barulah pengguna dapat melakukan penganotasian terhadap kalimat-kalimat yang telah ditambahkan. Terdapat dua cara untuk memberikan anotasi yaitu secara langsung di halaman Editor atau dapat juga dilakukan di Editable CCG Modal. Saat ini CCGtown belum mendukung penganotasian terhadap *compound words*. CCGtown saat ini juga belum mendukung penganotasian CCG dengan semantik. Versi awal CCGtown hanya mendukung penganotasian CCG secara sintaksis saja.

Setelah semua kata dalam suatu kalimat diberikan anotasi, pengguna dapat melakukan *generate CCG derivation*. Hal ini dapat dilakukan berkat bantuan *library* NLTK. Kami mengambil sebuah *rules* dari tabel *projects* dan kemudian kami mengambil semua *words* serta *categories* dari tabel *sentences* yang



**Gambar 5.** Alur proses *login* ke sistem CCG.

merupakan bagian dari proyek tersebut. Kolom *words* merupakan kumpulan kata dari kalimat yang telah di-*tokenize*. Adapun kolom *categories* merupakan anotasi CCG *category*-nya. *Pseudocode* untuk *generate CCG derivation* dapat dilihat pada Kode 3.1 dengan asumsi anotasi yang diberikan absah (dapat dibuat CCG *derivation*-nya). Kode *next* tersebut akan mengambil satu dari banyak kemungkinan *derivation* yang dapat dibuat. Contoh *object* yang di-*return* dapat dilihat pada Kode 3.2. Untuk kepentingan *rendering* di sisi *frontend*, *key* seperti *from* dan *to* sangat diperlukan. *Key from* dan *key to* merepresentasikan *index* posisi terhadap *array words*. Dengan bantuan kedua *key* tersebut, *frontend* dapat melakukan kalkulasi posisi masing-masing elemen yang terdapat di *object derivations*.

Kode 3.1: Pseudocode untuk melakukan *generate CCG derivation*.

---

```

1 from nltk.ccg import chart, lexicon
2
3 def generateCCGDerivation(rules, words, categories, target_words):
4     lex = rules + '\n\n'
5     for i in range(len(words)):
6         lex += words[i] + ' => ' + categories[i] + '\n'
7
8     lex = lexicon.parseLexicon(lex)
9     parser = chart.CCGChartParser(lex, chart.DefaultRuleSet)
10    result = next(parser.parse(target_words))
11    derivations = makeCCGDeriv(result)
12
13    return derivations

```

---

Kode 3.2 didapatkan dari fungsi *makeCCGDeriv* yang terdapat pada Kode 3.1. Fungsi *makeCCGDeriv* sederhananya mengambil *Tree* yang didapatkan dari *parser.parse* kemudian melakukan *tree traversal*. Semua *leaf*, diambil dari paling "kiri", diletakkan di elemen pertama *derivations*. Selanjutnya, kita berjalan melalui *parent* dari *leaf* tersebut hingga ke *root* mencari bentuk CCG *derivation*-nya. Banyaknya baris yang dibutuhkan oleh CCG *derivation* dapat dilihat dari *height* yang dimiliki oleh *Tree* tersebut. Kemudian, hasil dari CCG *derivation* (umumnya berupa *S*) merupakan elemen terakhir *derivations*. Adapun hasil *render* di sisi *frontend*-nya dapat dilihat pada Gambar 14.

Kode 3.2: Contoh *derivations object* yang di-*return*.

---

```

1 [
2   [
3     { "to": 0, "from": 0, "word": "You" },
4     { "to": 1, "from": 1, "word": "prefer" },
5     { "to": 2, "from": 2, "word": "that" },
6     { "to": 3, "from": 3, "word": "cake" }
7   ],
8   [
9     { "to": 0, "from": 0, "category": "NP" },
10    { "to": 1, "from": 1, "category": "((S\NP)/NP)" },
11    { "to": 2, "from": 2, "category": "(NP/N)" },
12    { "to": 3, "from": 3, "category": "N" }
13  ],
14  [
15    { "to": 3, "from": 2, "category": "NP", "operator": ">" }
16  ],
17  [
18    { "to": 3, "from": 1, "category": "(S\NP)", "operator": ">" }
19  ],
20  [
21    { "to": 3, "from": 0, "category": "S", "operator": "<" }
22  ]
23 ]

```

---

Selain memiliki kemampuan untuk melakukan *generate CCG derivation*, CCGtown juga memiliki kemampuan untuk melakukan *auto-assign CCG category*. Token kata yang sudah dianotasi oleh pengguna akan disimpan ke dalam suatu *dictionary*. Untuk setiap kata yang belum dianotasi, CCGtown akan memeriksa apakah token kata tersebut sebelumnya sudah dianotasi. Apabila sudah, CCGtown akan memberikan anotasi secara otomatis. Suatu token kata mungkin memiliki lebih dari satu anotasi. CCGtown hanya akan mengambil satu anotasi saja. Akibatnya, pengguna sebaiknya tetap melakukan peninjauan. Kendati demikian, setidaknya kegiatan anotasi yang repetitif dapat berkurang sehingga memudahkan dan mempercepat proses anotasi.

## Pertimbangan UI/UX

Secara keseluruhan, CCGtown memiliki halaman rumah (*homepage*), halaman *register*, halaman *login*, halaman *Projects*, dan halaman *Editor*. Halaman *register* dan halaman *login* pada dasarnya sama. Perbedaanannya hanya terdapat di jumlah *field* yang diminta serta *copy writting* yang sedikit berbeda.

Desain UI<sup>13</sup> serta UX<sup>14</sup> CCGtown dibuat dengan fokus untuk mempermudah penggunaan *annotation tool* ini. CCGtown tidak menggunakan banyak warna. Hal ini untuk mengurangi kelelahan pada mata pengguna. CCGtown menggunakan bahasa Inggris di antarmukanya karena target pengguna CCGtown adalah pengguna baik dari Indonesia yang mengerti bahasa Inggris maupun pengguna dari manca negara.

CCGtown menggunakan UIKit<sup>15</sup> sebagai *framework* untuk melakukan implementasi desain web-nya. UIKit dipilih karena komponen-komponen yang dibutuhkan CCGtown sudah tersedia sehingga CCGtown hanya perlu melakukan sedikit penyesuaian seperti penambahan warna, pengaturan jarak (*margin* dan *padding*), dan sejenisnya. UIKit juga sudah menyediakan kumpulan *icons* yang dapat langsung digunakan. Hal ini mengakibatkan proses pengembangan desain web CCGtown dapat diselesaikan dalam waktu yang relatif cukup singkat.

Warna utama (*primary color*) CCGtown adalah warna ungu. Berdasarkan psikologi warna, warna ungu adalah warna fantasi dan magis. CCGtown dapat *men-generate* CCG *derivation* dan melakukan *auto-assign* CCG *category* sehingga memiliki sifat yang seakan-akan mengandung magi (sihir). Selain itu, ungu menumbuhkan kreativitas dengan membangkitkan indra kita sambil mempromosikan ketenangan yang diperlukan untuk melakukan pengamatan yang intuitif dan berwawasan. Warna ungu banyak digunakan oleh *homepage* seperti yang terlihat pada Gambar 6. Halaman rumah CCGtown didesain sederhana dan langsung kepada intinya. Halaman rumah CCGtown menampilkan beberapa fitur yang dapat menjadi alasan bagi pengguna untuk menggunakan CCGtown. Selain itu, halaman rumah CCGtown juga menampilkan demonstrasi singkat dengan gambar animasi proses pengannotasian di CCGtown. Demonstrasi singkat diberikan untuk memberikan gambaran kepada calon pengguna tentang betapa mudahnya menggunakan CCGtown untuk menganotasi CCG.

Pada Gambar 7 dan Gambar 8, terlihat bahwasannya halaman *register* dan halaman *login* pada dasarnya sama. Pada halaman *register*, informasi yang dibutuhkan hanyalah *email address* dan *password* (dengan tambahan *password confirmation* untuk validasi). Hal ini agar pengguna dapat dengan mudah mendaftar tanpa perlu mengisi banyak *field* terlebih dahulu sebelum dapat menggunakan CCGtown. Selain itu, informasi lain dari pengguna saat ini belum dibutuhkan. Apabila terjadi perubahan mengenai data pengguna, pengguna dapat memperbarui datanya di kemudian hari melalui halaman lain seperti halaman profil yang mungkin saja akan ditambahkan di CCGtown versi berikutnya.

CCGtown menggunakan *flash message* berupa *toast* untuk setiap pesan *feedback* yang diberikan oleh sisi *backend*. Sebagai contoh, pada Gambar 9 di bagian pojok kanan bawah merupakan pesan *feedback* yang memberikan informasi bahwasannya kombinasi *email* dan/atau *password* tidak cocok sehingga pengguna tidak dapat *login*. Notifikasi *toast* tersebut dapat langsung ditutup oleh pengguna atau akan hilang dengan sendirinya dalam waktu sekitar lima detik. Penggunaan *toast* yang muncul dari bawah dengan warna ungu tersebut dapat mengalihkan perhatian pengguna sehingga pengguna menyadari pesan yang disampaikan oleh *backend* CCGtown.

Selanjutnya, dengan asumsi pengguna baru saja mendaftar kemudian melakukan *login*, pengguna akan dialihkan ke halaman Projects. Halaman Projects tersebut berada di dalam *empty state* karena pengguna belum membuat satupun proyek. Seperti yang dapat dilihat pada Gambar 10, pengguna dapat melihat instruksi apa yang harus ia lakukan yang mana dalam hal ini adalah membuat proyek baru. Sebaliknya, apabila pengguna telah membuat proyek maka tampilan yang dilihat akan seperti pada Gambar 11. Pengguna dapat membuka halaman Editor dengan cara melakukan klik di nama proyek maupun di ikon *edit*. Selain itu, pengguna juga dapat langsung melakukan *export to JSON* melakukan klik di ikon *download*. Apabila pengguna merasa tidak lagi memerlukan suatu proyek, maka pengguna dapat menghapusnya dengan melakukan klik di ikon *trash*.

Setelah membuat proyek baru, pengguna akan melihat halaman Editor dalam *empty state* seperti yang dapat dilihat pada Gambar 12. Pada bagian kanan halaman Editor, terdapat beberapa *section* yaitu Project Detail yang dapat digunakan untuk mengubah nama proyek dan status proyek, Automation Rules yang akan digunakan oleh NLTK untuk melakukan *generate CCG derivation*, serta CCG Lexicons yang menampilkan statistik dari jenis sintaksis CCG yang telah dianotasikan dan berapa kali ia dianotasikan. Untuk dapat menambahkan kalimat baru, pengguna hanya perlu melakukan klik di tombol "Add Sentences". Setelah itu, pengguna dapat langsung melakukan pengannotasian seperti yang terlihat pada Gambar 13. Apabila pengguna telah memberikan anotasi ke semua token kata yang ada di kalimat tersebut, pengguna dapat melakukan *generate CCG derivation*. Hasil dari *generate CCG derivation* tersebut dapat dilihat pada Gambar 14.

Pengguna juga dapat langsung mengubah CCG *derivation* suatu kalimat secara langsung. Contohnya

---

<sup>13</sup>User Interface

<sup>14</sup>User Experience

<sup>15</sup><https://getuikit.com/>

dapat dilihat pada Gambar 15. Pengguna dapat memberikan anotasi ke token kata di *modal (editable CCG derivation)* tersebut. Pengguna dapat menambahkan beberapa baris kosong sekaligus yang kemudian akan diisi oleh CCG *derivation* dari kalimat tersebut. Warna abu-abu menunjukkan bahwa konfigurasi dari CCG *derivation* di baris tersebut masih kosong. Kemudian, warna ungu menunjukkan bahwa pada bagian tersebut (baik anotasi maupun operator) tidak diisi. Perbedaan ini diberikan untuk memberikan pengguna *awareness* mengenai mana saja bagian yang harus diisi atau dilengkapi. Adapun konfigurasi *derivation*-nya terlihat pada Gambar 16. Dengan kemampuan ini pengguna dapat melakukan *generate* kemudian apabila ada *derivation* yang dirasa kurang cocok maka pengguna dapat langsung melakukan perubahan dengan mudah dan interaktif.

## 4. Evaluasi

TBA.

### 4.1 Hasil Pengujian

TBA.

### 4.2 Analisis Hasil Pengujian

TBA.

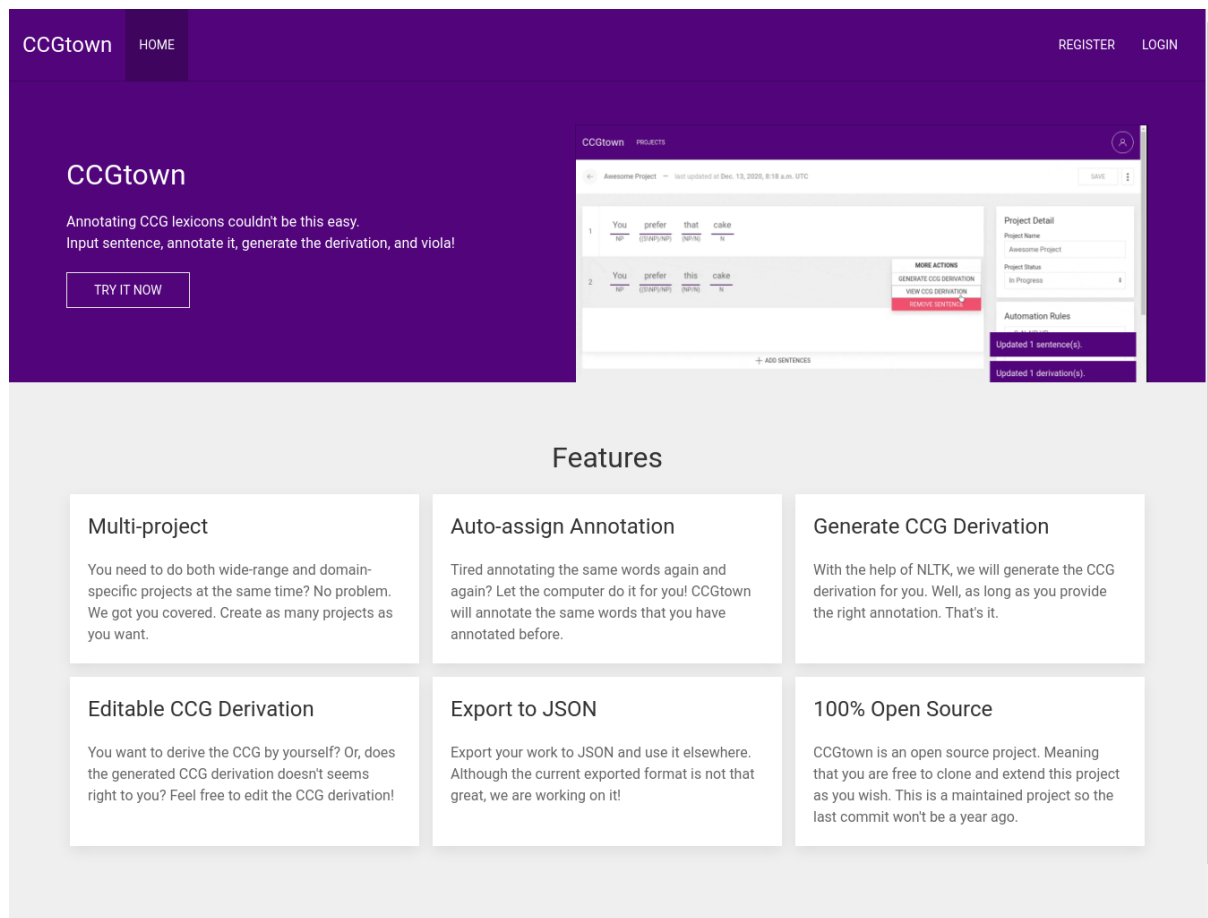
## 5. Kesimpulan

TBA.

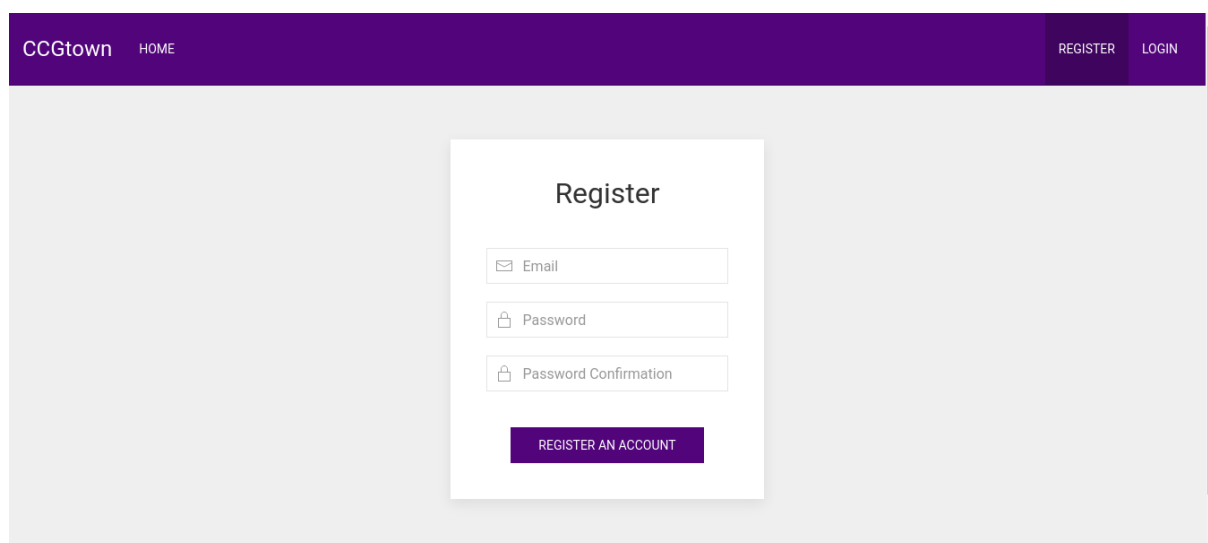
## Daftar Pustaka

- [1] K. Evang, L. Abzianidze, and J. Bos. CCGweb: a new annotation tool and a first quadrilingual CCG treebank. In *Proceedings of the 13th Linguistic Annotation Workshop*, pages 37–42, Florence, Italy, Aug. 2019. Association for Computational Linguistics.
- [2] J. Hockenmaier and M. Steedman. CCGbank: A corpus of CCG derivations and dependency structures extracted from the Penn treebank. *Computational Linguistics*, 33(3):355–396, 2007.
- [3] J. Lambek. *Categorial and Categorical Grammars*, pages 297–317. Springer Netherlands, Dordrecht, 1988.
- [4] K. Malvoni, S. Designer, and J. Knezovic. Are your passwords safe: Energy-efficient bcrypt cracking with low-cost parallel hardware. 08 2014.
- [5] K. V. Nguyen and N. L.-T. Nguyen. Vietnamese transition-based dependency parsing with supertag features, 2019.
- [6] R. Rojas. A tutorial introduction to the lambda calculus. *CoRR*, abs/1503.09060, 2015.
- [7] M. Steedman. Categorical grammar. Technical report, 1992.
- [8] M. Steedman. A very short introduction to ccg. Technical report, 1996.

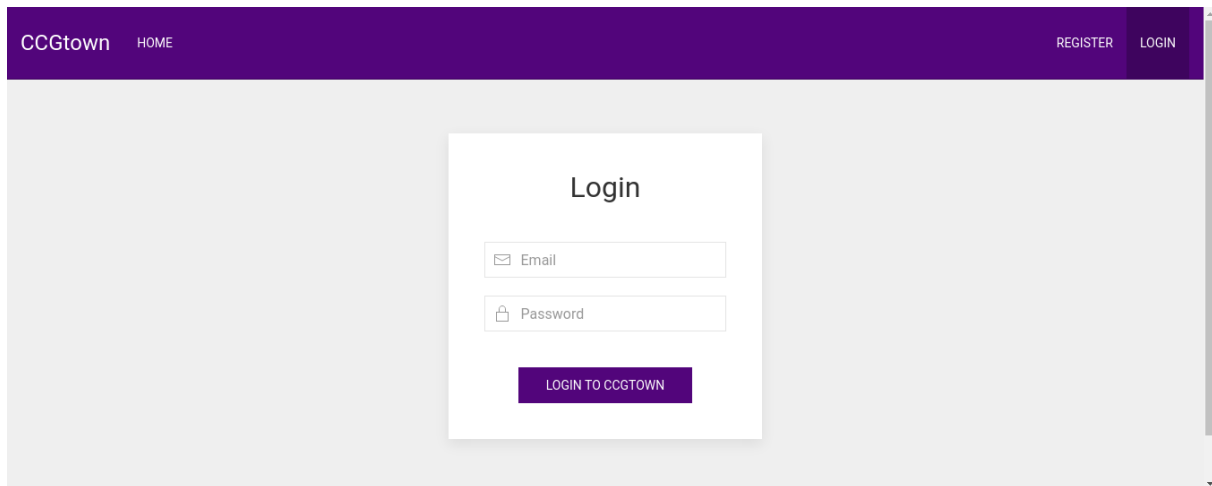
## Lampiran



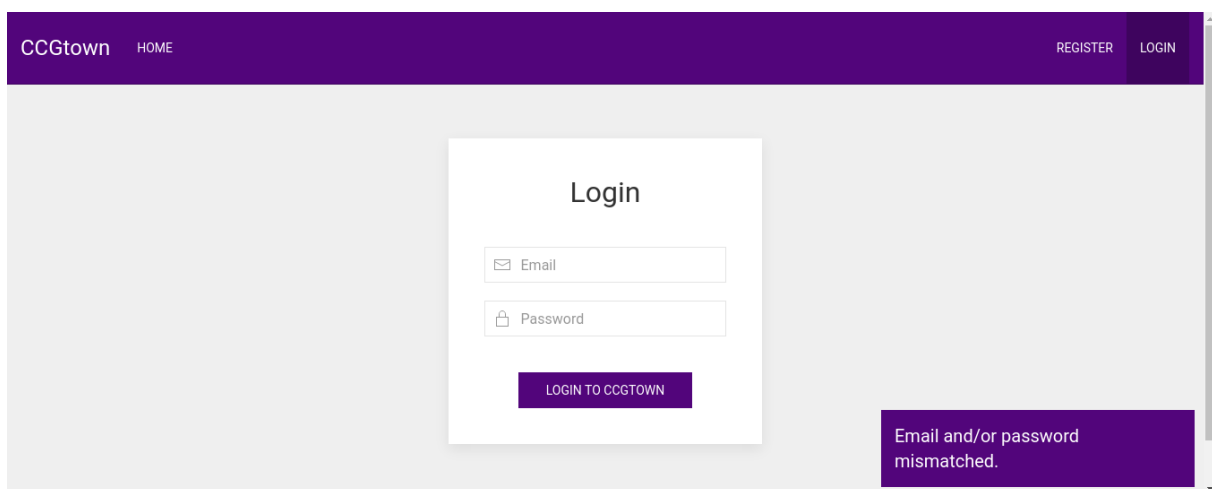
**Gambar 6.** Antarmuka *homepage* CCGtown.



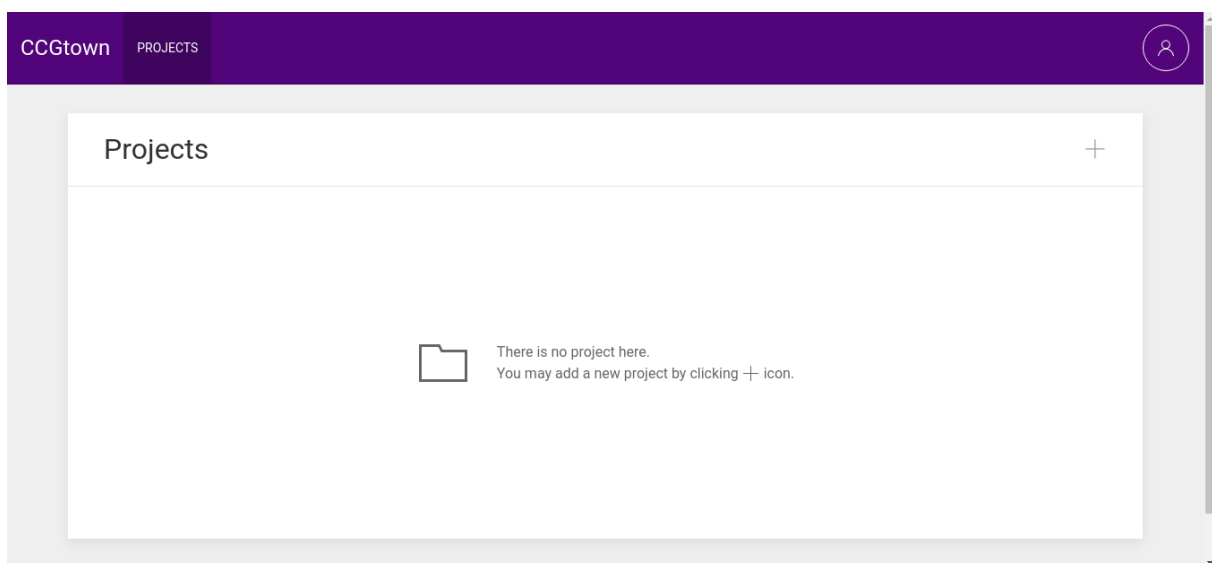
**Gambar 7.** Antarmuka halaman *register* CCGtown.



**Gambar 8.** Antarmuka halaman *login* CCGtown.

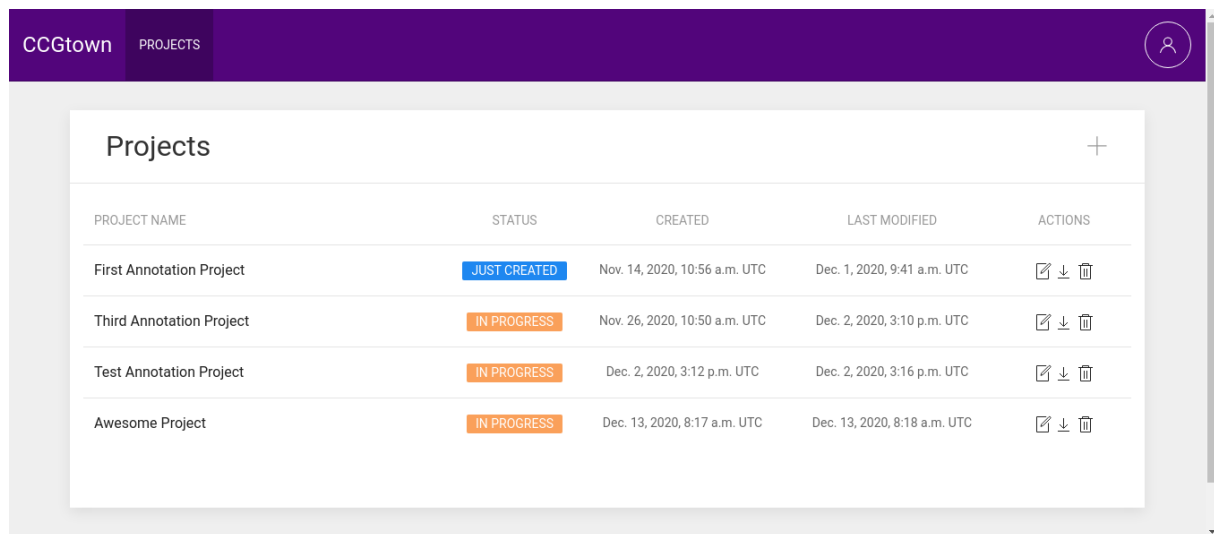


**Gambar 9.** Antarmuka halaman *login* CCGtown dengan *toast*.



**Gambar 10.** Antarmuka halaman Projects saat dalam *empty state*.

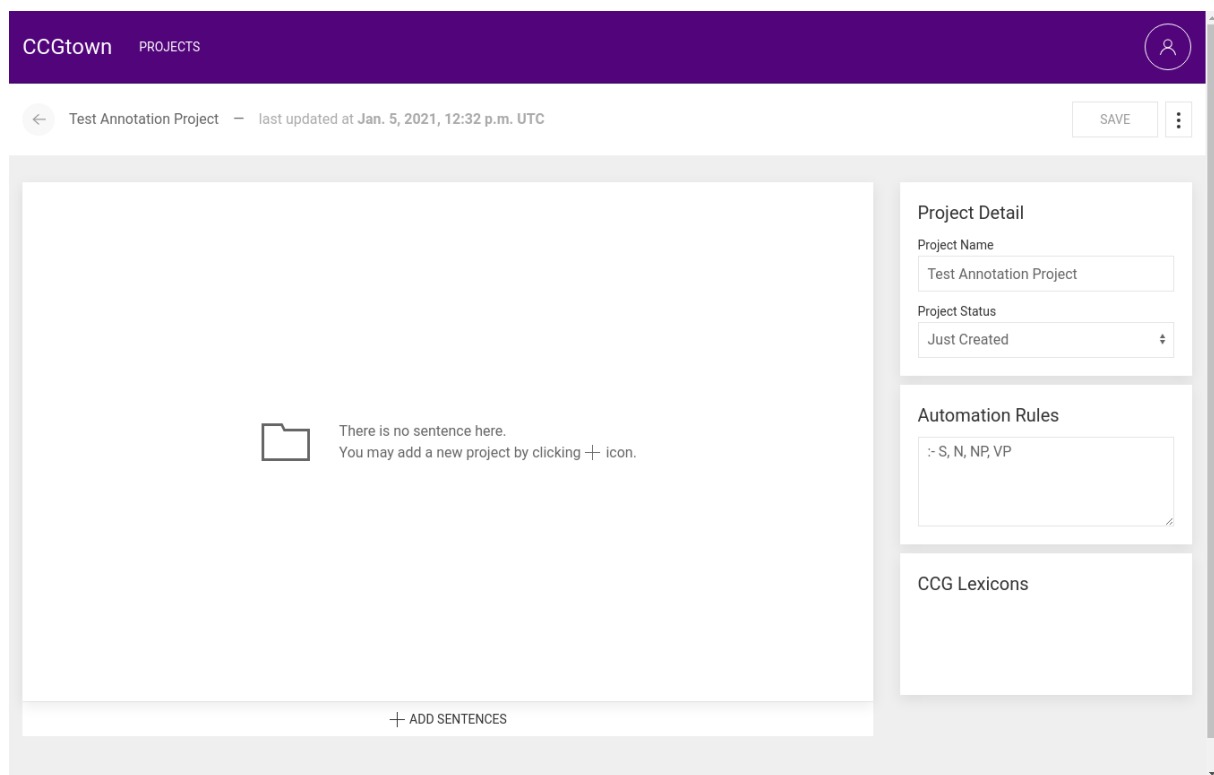




The screenshot shows the 'Projects' page in CCGtown. It features a purple header with 'CCGtown' and 'PROJECTS' tabs, and a user profile icon. Below the header is a 'Projects' section with a table listing four projects. Each project row includes the project name, status (JUST CREATED or IN PROGRESS), creation date, last modified date, and action icons (edit, download, delete).

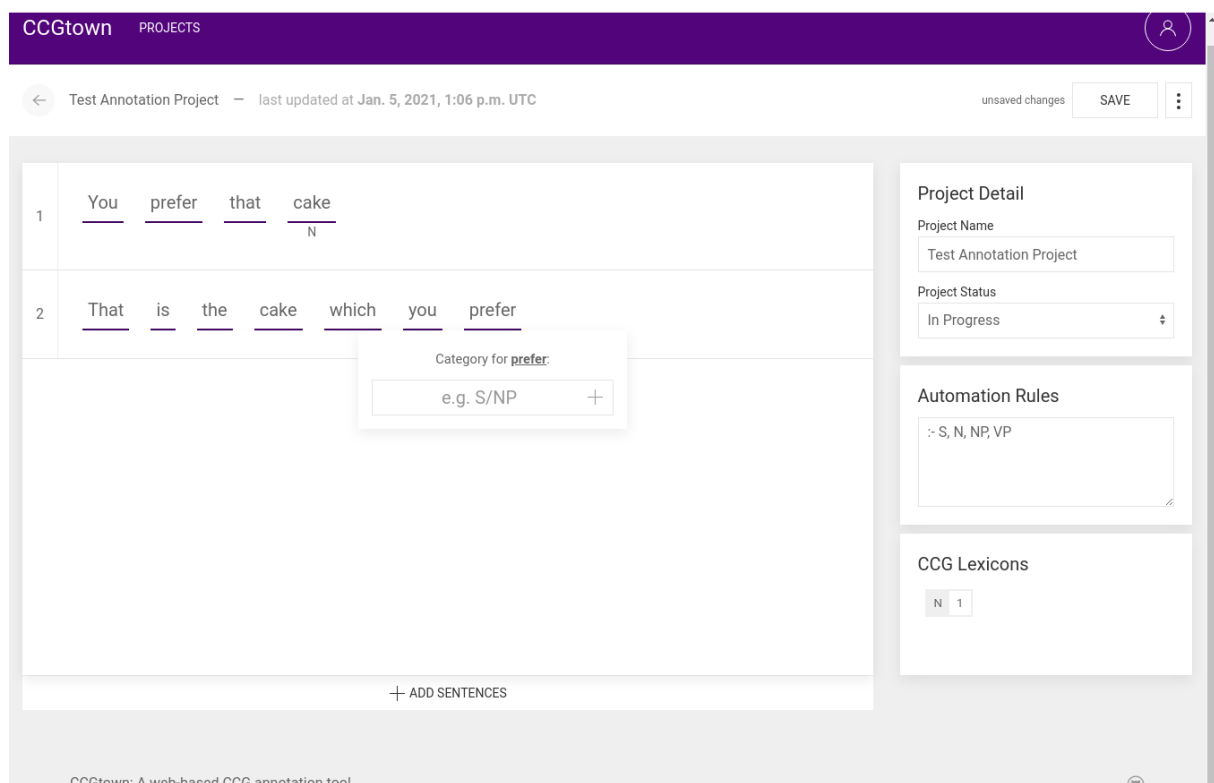
PROJECT NAME	STATUS	CREATED	LAST MODIFIED	ACTIONS
First Annotation Project	JUST CREATED	Nov. 14, 2020, 10:56 a.m. UTC	Dec. 1, 2020, 9:41 a.m. UTC	
Third Annotation Project	IN PROGRESS	Nov. 26, 2020, 10:50 a.m. UTC	Dec. 2, 2020, 3:10 p.m. UTC	
Test Annotation Project	IN PROGRESS	Dec. 2, 2020, 3:12 p.m. UTC	Dec. 2, 2020, 3:16 p.m. UTC	
Awesome Project	IN PROGRESS	Dec. 13, 2020, 8:17 a.m. UTC	Dec. 13, 2020, 8:18 a.m. UTC	

**Gambar 11.** Antarmuka halaman Projects CCGtown.



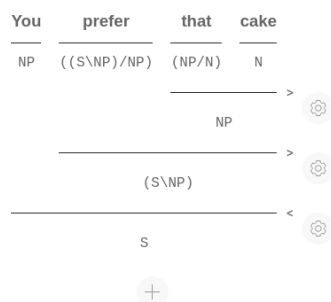
The screenshot shows the 'Editor' page in CCGtown. It features a purple header with 'CCGtown' and 'PROJECTS' tabs, and a user profile icon. Below the header is a breadcrumb trail: 'Test Annotation Project' - last updated at Jan. 5, 2021, 12:32 p.m. UTC. A 'SAVE' button and a menu icon are also visible. The main content area is divided into two sections: a large text area on the left and a sidebar on the right. The text area contains a folder icon and the message: 'There is no sentence here. You may add a new project by clicking + icon.' At the bottom of the text area is a '+ ADD SENTENCES' button. The sidebar contains three sections: 'Project Detail' with fields for 'Project Name' (Test Annotation Project) and 'Project Status' (Just Created); 'Automation Rules' with a text input field containing ':- S, N, NP, VP'; and 'CCG Lexicons' with an empty text input field.

**Gambar 12.** Antarmuka halaman Editor saat dalam *empty state*.

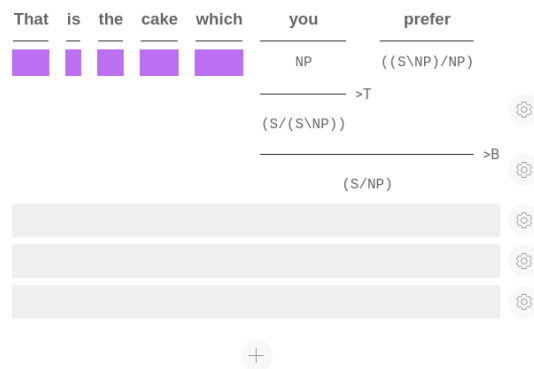


**Gambar 13.** Antarmuka halaman Editor saat melakukan penganotasian.

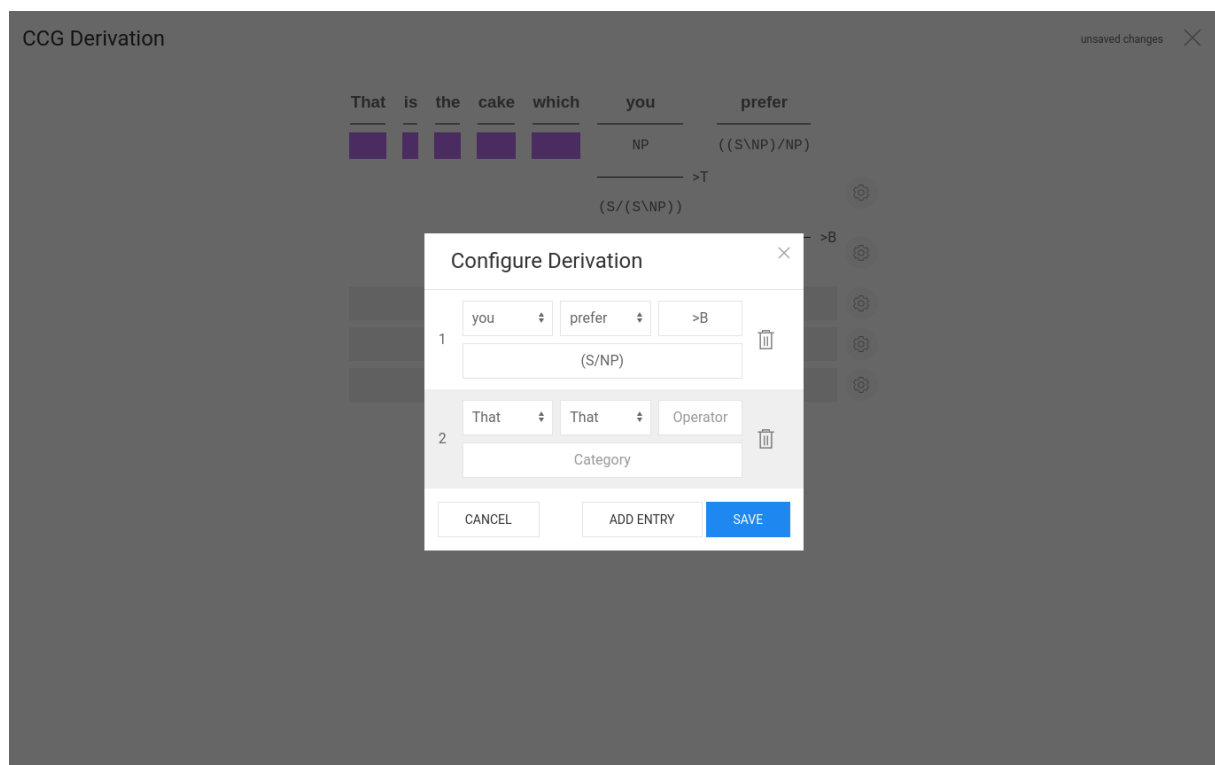
#### CCG Derivation



**Gambar 14.** Antarmuka CCG *derivation* yang telah di-generate.



**Gambar 15.** Antarmuka *editable CCG derivation* CCGtown.



**Gambar 16.** Antarmuka konfigurasi dari *editable CCG derivation* CCGtown.